

OA-WAM: 用于鲁棒机器人操作的对象可寻址世界动作模型

Yushan Liu¹ Peibo Sun² Shoujie Li³ Yifan Xie¹
Lingfeng Zhang¹ Xintao Chao¹ Shiyuan Dong²
Fang Chen² Xiao-Ping Zhang¹ Wenbo Ding^{1*}

¹ 清华大学

² 上海交通大学

³Nanyang Technological University

摘要

世界动作模型 (World Action Models, WAM) 通过联合预测场景演化和机器人动作来增强视觉-语言-动作 (Vision-Language-Action, VLA) 策略。然而, 多数现有方法把预测世界表示为整体图像、视频 token 流或全局潜变量; 当指令指向某个具体目标物体时, 动作解码器很难稳定定位该物体: 在新的场景偏移下, 相关物体通常仍然可见, 但整体式 token 会把其身份与周围上下文纠缠在一起。本文将这一问题刻画为缺乏对象可寻址性, 并提出 OA-WAM, 即用于鲁棒机器人操作的对象可寻址世界动作模型。每一帧被分解为 $N+1$ 个逐槽位状态 token (1 个机器人槽位、 N 个物体槽位), 每个 token 拼接身份向量 addr_k 和随时间变化的内容向量 content_k^t , 再与文本、图像、本体感知和历史动作 token 融合成块因果序列。世界头回归下一帧槽位状态, 流匹配动作头解码 16 步连续动作块, 二者在一次前向传播中同时完成。OA-WAM 在架构上通过每个 Transformer 层中仅基于 addr 路由跨槽位注意力来强制对象可寻址性, 即采用仅地址键投影, 并在每层重置残差流中的地址切片。这在张量层面把“要操作哪个物体”和“该物体当前是什么状态”分离开来, 在不引入额外 token 的情况下提供可干预的对象级接口。OA-WAM 在 LIBERO (97.8%) 和 SimplerEnv (79.3%) 上达到与 SOTA VLA 和 WAM 基线相当的性能; 在 LIBERO-Plus 上, OA-WAM 在最符合本文假设的几何轴上取得新的 SOTA, 同时在七轴总体指标上仍与 $\pi_{0.5}$ 保持竞争力 (83.9% vs 85.7%)。因果槽位干预测试中, OA-WAM 的交换绑定余弦为 0.87, 而所有整体式基线均不超过 0.09。结果表明, 将世界模型显式组织为可寻址的对象状态, 是在场景扰动下实现更鲁棒机器人操作的有效路径。

1 引言

机器人操作天然发生在对象层面。诸如“把红色杯子放到绿色托盘上”的指令, 并不是要求机器人复现一条训练轨迹; 它要求机器人在当前场景中识别语言命名的物体, 推理它们与周围干扰物之间的空间和功能关系, 并生成正确、鲁棒的闭环动作。视觉-语言-动作 (VLA) 策略通过扩展视觉语言主干、机器人数据和动作解码器, 在标准操作基准上取得了快速进展 [32, 60, 102]; 世界动作模型 (WAM) 进一步联合预测动作和未来世界状态, 为策略提供额外的时间与因果监督 [9, 89, 90]。

然而, 鲁棒性基准表明, 标准基准上的高分并不意味着可靠的场景理解: 当物体布局、相机视角、机器人初始状态、背景、光照或传感器噪声发生温和扰动时, 策略常常从近乎饱和的成功率迅速崩溃 [19, 23, 61], 并且对改写后的甚至无意义的指令 token 仍不敏感 [19, 99]。

*通讯作者。



图 1: OA-WAM 概览。在场景扰动下（左，六类典型扰动轴），整体式 WAM 会在全局 token 中纠缠目标身份与上下文，并漂移到错误动作（右上）。本文的 OA-WAM（右下）把每一帧分解为 $N+1$ 个可寻址对象槽位，其跨槽位注意力键只读取身份地址子向量，从而保持鲁棒操作。

这两点都说明，目标选择绑定的是训练布局和视觉上下文，而不是语言命名的物体。多数现有 WAM 仍把预测世界表示为整帧观测、图像/视频 token 流或共享的全局视觉-动作潜变量 [10, 95, 101]；这些表示能捕捉场景如何演化，却没有给动作解码器提供稳定接口来判断应该操作哪个物体。当相机、布局或机器人位姿变化时，目标物体通常仍然可见，却会在整体式 token 中与背景和邻近内容纠缠，导致动作选择漂移。

对象中心工作试图弥补这一缺口：基于槽位的动力学模型提升了样本效率和关系推理能力 [20, 29]，对象状态 grounding 则把对象表示转化为语言与动作之间的操作接口 [13, 26, 88]。但许多方法依赖从零开始的 Slot-Attention 式发现 [50, 81, 82]，容易受固定槽位数、遮挡和杂乱场景影响；即使得到稳定槽位，每个槽位仍混合身份、外观、位姿和局部上下文，因此动作解码器在扰动下仍可能漂移到错误实例。

基于这一诊断，本文提出 OA-WAM，一种对象可寻址的 WAM。每一帧被分解为 $N+1$ 个槽位，其向量拆分为冻结的身份地址 addr_k 和随时间变化的内容 cnt_k^t 。前者在每个 episode 中仅根据语言标签和初始 DINOv3 特征计算一次，此后不再更新；后者则每一步由 SAM 3 + DINOv3 掩码刷新。槽位与文本、图像 VQ、本体感知和历史动作流融合成块因果序列，由 7B Chameleon 风格主干处理；世界头回归下一帧逐槽位 $(\hat{\text{cnt}}, \hat{\text{pose}})$ ，流匹配动作头在一次前向传播中解码 16 步连续动作块。OA 约束由两个无参数的张量级操作实现，并施加在 32 个 Transformer 层的每一层：跨槽位键投影只读取 addr 子向量，前向钩子把残差中的 addr 切片重置为缓存身份。由于 addr 在 episode 内冻结，且重置阻断了流向它的梯度，每个 Transformer 层的槽位路由键在架构上被限制为只依赖冻结的身份地址。在上游槽位提取正确的条件下，这消除了整体式主干的一种具体失效模式，即场景上下文偏移无法再改写动作头读取的槽位；内容、位姿和语言仍可通过残差流和值投影自由流动。该约束作用于键路由，而不是端到端语义正确性的保证，并会继承 SAM 3 + Qwen3-VL 槽位流程产生的错误。

在三个基准上，OA-WAM 在假设预测的区域验证了该设计。在分布内 LIBERO 和 SimplerEnv WidowX (Visual Matching) 上，其平均成功率达到 97.8 和 79.3，领先所有已发表的 VLA 和 WAM 基线（表 1）。在 LIBERO-Plus 鲁棒性基准上（表 2），它在与假设最一致的几何轴上达到新的 SOTA：相机轴 80.5（比 Cosmos-Policy 高 +4.7%）、机器人初始状态 89.6（与 X-VLA 相差 0.1% 内），Camera/Robot/Layout 几何轴平均为 84.3（比 $\pi_{0.5}$ 高 +4.8%）；七轴总平均为 83.9，接近 $\pi_{0.5}$ 的 85.7，残余差距集中在 Sensor Noise 轴，其光度破坏主要干扰感知阶段的槽位提取，而非动作策略本身。因果槽位干预测试中，OA-WAM 的交换绑定余弦为 0.87，而八个整体式基线均不超过 0.09，直接给出目标选择扎根于显式地址子空间的行为证据；




图 2: **OA-WAM 架构**。多模态输入被编码为各类 token 流：对象槽位 token 由 SAM3+DINOv3 得到，并通过可学习的槽位适配器投影；只有槽位 token 引入可学习参数，其余 token 复用冻结的 embed tokens。这些 token 被组装为块因果序列，末尾接一个可学习动作查询 [ACT-Q]，再由槽位感知主干处理。世界头读取槽位隐藏状态，预测下一帧逐槽位 (cnt, pose) 作为辅助监督；动作头解码 16 步动作块。

OA 隔离消融进一步表明，仅关闭地址专用键投影就会使 LP camera 下降 13.3%，而分布内 LIBERO 几乎不变 (-1.5%)，呈现出 OOD 特定归纳偏置而非通用容量增益的非对称特征。

本文贡献如下：

- 本文把现有 WAM 在操作扰动下鲁棒性不足的问题建模为缺乏对象可寻址性：世界状态不仅应预测未来，还应提供稳定的逐对象状态，使语言条件动作生成能够直接查询任务相关物体。
- 本文提出 OA-WAM，它使用逐槽位 addr/content 状态 token、块因果世界-动作序列、时间对齐的世界/动作头，以及由“仅地址键投影 + 每层地址流重置”组成的两部分 OA 约束，从架构上解耦对象身份寻址与随时间变化的内容建模。
- 本文在标准 LIBERO 和 SimplerEnv 上达到 SOTA 级性能，并在 LIBERO-Plus 中与假设最直接的相机和机器人初始状态轴上领先；消融和槽位干预测试确认，对象可寻址接口是该鲁棒性模式的关键来源。

2 相关工作

具有整体式未来预测的世界动作模型。 世界动作模型把动作策略与世界模型目标耦合起来，使策略学习其动作如何改变场景。从潜空间想象控制 (Dreamer V3, TD-MPC2) [24, 25] 和文本条件视频规划 (UniPi, RoboDreamer, ManipDreamer, NovaPlan) [16, 21, 41, 98]，到统一的动作-未来模型，包括耦合扩散 (UWM)、交错自回归流 (WorldVLA, RynnVLA-002, UniVLA)、JEPA 风格和潜变量 WAM (VLA-JEPA, Being-H0.7)、记忆或世界链推理 (MemoryVLA, CoT-VLA, CoWVLA, AdaWorldPolicy, dreamzero, lingbotva)、生成-动作桥接 (F1)、基础视频策略微调 (GE-Act, Cosmos-Policy)，以及近期面向测试时效率 (Fast-WAM)、条件空间世界表示 (World Guidance)、组合式世界模型 (RISE) 和正反向验证 (WAV) 的变体 [9, 10, 34, 38, 42, 49, 51, 52, 66, 72, 73, 79, 85, 86, 89-91, 95, 101]，这些模型在像素空间、

自回归 token 流或全局潜变量中预测未来，提供额外的时间监督，但并不给出分解且可查询的视图来表示指令命名的各个物体。OA-WAM 把世界预测重构为逐对象槽位状态预测，补上整体式世界目标缺失的可寻址对象级接口。

鲁棒操作策略。 视觉-语言-动作 (VLA) 策略主导闭环操作。从 RT-1/2 和 Open X-Embodiment / Octo [5, 57, 58, 102] 开始，这一路线通过微调 VLM 主干 (OpenVLA, RDT, GR00T N1.5, SpatialVLA, NORA, SmolVLA, X-VLA, ABot-M0, InternVLA-M1) [14, 28, 32, 48, 56, 62, 69, 87, 97]、加入流匹配或优化动作头 ($\pi_0/\pi_{0.5}$, OpenVLA-OFT) [3, 33, 60]，并结合视觉运动设计 (ACT, Diffusion Policy, Transporter, CLIPort, PerAct, VIMA) [15, 30, 67, 68, 92, 96] 来扩展能力，已接近饱和标准基准。然而，近期压力测试 [19, 23, 61, 76, 99] 揭示了温和场景扰动下的崩溃以及策略对语言改写的不敏感；STRONG-VLA [84] 等训练侧修复仍保持感知接口不变，因此策略仍把“要操作哪个物体”绑定到训练布局和视觉上下文，而不是语言命名目标。OA-WAM 在架构层面处理这一问题：把目标选择锚定到冻结的、语言 grounding 的身份向量，使其对场景内容保持不变，从而让鲁棒性成为主干的结构属性，而非训练数据的结果。

对象中心表示。 对象中心表示把场景分解为对象级潜状态。从生成式分解模型 (MONet, IODINE, GENESIS, STEVE) [6, 18, 22, 71] 和 Slot-Attention 家族 (Slot Attention, SAVi, SAVi++, SlotFormer, SlotDiffusion) [17, 35, 50, 81, 82]，到把对象槽位与基于模型的强化学习相结合的机器人工作 (FOCUS, SOLD) [20, 54] 以及语言条件策略 (OCWM, Goal-VLA, SlotVLA, OAT-VLA, ObeyedVLA, STORM, LiLo-VLA) [2, 12, 13, 26, 29, 74, 88]，再到用基础感知 (SAM/SAM 2/SAM 3, DINO/DINOv2/DINOv3, CLIP, SigLIP, T5, Qwen3-VL) [1, 7, 8, 36, 59, 63–65, 70, 93] 稳定槽位发现，这一系列方法要么仍对槽位数、遮挡和杂乱敏感，要么在获得稳定槽位后，仍把每个物体的身份、外观、位姿和上下文编码在同一向量中，使动作解码器没有架构保证可将“要操作哪个物体”与“该物体当前是什么状态”解耦。OA-WAM 通过把每个槽位划分为冻结身份地址和时变内容子向量，并在每个 Transformer 层中仅通过地址子向量路由跨槽位注意力来弥合这一缺口。这是在张量层面、无参数地承诺可寻址路由（条件是上游语言 grounding 槽位提取正确），此前世界模型或 VLA 模型并未提供这种机制。

3 方法

3.1 问题设置

在步骤 t ，智能体观测 RGB 帧 $\mathbf{I}_t$ （第三人称与腕部视角）、本体感知 $\mathbf{q}_t \in \mathbb{R}^7$ 、语言指令 ℓ ，以及过去 $T-1$ 个已执行动作 $\mathbf{a}_{<t}$ 。策略 π_θ 在一次前向传播中生成动作块 $\mathbf{A}_t = (\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}) \in \mathbb{R}^{H \times 7}$ ($H=16$)，并预测逐对象下一帧状态 $\hat{\mathcal{S}}_{t+1} = \{(\hat{\mathbf{c}}_k^{t+1}, \hat{\mathbf{p}}_k^{t+1})\}_{k=1}^N$ ：

$$(\mathbf{A}_t, \hat{\mathcal{S}}_{t+1}) \sim \pi_\theta(\mathbf{I}_{\leq t}, \mathbf{q}_{\leq t}, \ell, \mathbf{a}_{<t}). \quad (1)$$

OA-WAM 基于对象级输入表示来参数化 π_θ ：每一帧被分解为 $N+1$ 个槽位，并约束跨槽位注意力键只依赖对象身份。

3.2 对象槽位 token 化与统一序列

冻结的基础感知模块产生六条并行 token 流，共享同一条 Chameleon-7B 序列 [11, 46]：BPE 文本；Qwen3-VL [1] 名词短语（只作为 SAM 3 提示，不进入主干）；Chameleon VQ-GAN 图像码；SAM 3 [7]+DINOv3 [70]+ 位姿对象槽位；256 桶离散化本体感知；以及 256 桶离散化历史动作。五条流复用预训练 Chameleon 嵌入表，只有槽位流引入新参数。对帧 t 中的每个槽位 k ，构造 320 维槽位向量

$$\mathbf{s}_k^t = [\underbrace{\mathbf{addr}_k}_{32} \parallel \underbrace{\mathbf{cnt}_k^t}_{256} \parallel \underbrace{\boldsymbol{\pi}^t}_{16} \parallel \underbrace{\boldsymbol{\rho}_k}_{16}] \in \mathbb{R}^{320}, \quad (2)$$

其中 $\mathbf{addr}_k = f_{\text{addr}}([\ell_k \parallel \mathbf{f}_k^{(0)}])$ 在 $t=0$ 由语言标签和初始 DINOv3 特征计算一次，并在整个 episode 中固定（对象身份）； $\mathbf{cnt}_k^t = f_{\text{cnt}}(\mathbf{raw}_k^t)$ 每帧重新计算（时变状态）； $\boldsymbol{\pi}^t$ 是帧索引的正弦嵌入； $\boldsymbol{\rho}_k$ 是三个角色标签（robot, object, padding）上的可学习查表。槽位适配器 $f_\phi: \mathbb{R}^{320} \rightarrow \mathbb{R}^{4096}$ 将每个槽位投影到主干隐藏维度，并通过 LLaVA 风格的 masked_scatter 模式 [37, 47] 用槽位嵌入替换输入序列中的 $\langle \text{slot} \rangle$ 占位位置。完整序列在帧组之间块因果，并以可学习查询 token $[\text{ACT_Q}]$ 结束；动作头读取该 token 的最终隐藏状态。槽位容量固定为 $N_{\text{max}}=16$ ，未使用位置用掩码填充；多实例名词短语在 $t=0$ 由 Qwen3-VL 关系图消歧，身份则通过 SAM 3 概念跟踪跨帧保持（附录 B）。

3.3 对象可寻址注意力

7B 主干是 Chameleon 风格的多模态自回归 Transformer (32 层, 隐藏维度 4096, 32 个注意力头)。在槽位类型位置, 标准自注意力被替换为槽位感知变体, 其中键投影输入被限制为地址子向量 (图 3; 帧内槽位为双向注意力以保持置换等变, 帧间为块因果):

$$\begin{aligned} \mathbf{K}_k^{(\ell)} &= W_K^{(\ell)} \cdot \text{mask}_{\leq 32}(\mathbf{x}_k^{(\ell)}), \\ \mathbf{Q}_k^{(\ell)} &= W_Q^{(\ell)} \mathbf{x}_k^{(\ell)}, \quad \mathbf{V}_k^{(\ell)} = W_V^{(\ell)} \mathbf{x}_k^{(\ell)}, \end{aligned} \quad (3)$$

$\text{mask}_{\leq 32}$ 将前 32 维之外的所有坐标置零。这等价于只把 addr_k 通过 W_K 的 32 维切片投影, 但实现为投影前掩码, 因此可复用预训练 W_K , 不引入 OA 专用参数; 非槽位位置使用未修改的基础注意力 (逐模块统计见附录 D)。每个 Transformer 块之后, 前向钩子

会在槽位位置执行 $\mathbf{x}_k^{(\ell+1)}[1:32] \leftarrow \text{addr}_k$, 覆盖前 32 个输出坐标, 同时保持其余 4064 个坐标不变, 从而防止地址通过残差更新漂移。与式 (3) 结合后, 该机制从构造上确保每一层的槽位路由键信号只依赖冻结的身份地址: 在槽位提取正确的条件下, 动作头关注哪个槽位由 addr 决定, 而不是由 cnt_k^t 、场景上下文或非槽位 token 决定; 时变内容仍通过值和残差流传播。这是键路由的架构属性, 并非端到端 grounding 正确性的语义保证; 如果 SAM 3 漏检物体, 或两个槽位初始化为模糊地址, 路由约束无法修复上游错误。整体式 VLA 主干 [32, 56, 60] 在单一 patch-token 流中纠缠身份、外观与周围上下文; OA-WAM 在张量层面将它们分离。




图 3: OA 注意力掩码。帧间块因果; 帧内槽位双向可见 (红色对角块)。 W_K 只读取 addr_k (前 32 维)。

3.4 预测头

三个预测头读取最终隐藏状态 $\mathbf{H} \in \mathbb{R}^{B \times L \times 4096}$ 。世界头 h_ψ 将逐槽位隐藏状态输入两个并行 MLP: 内容分支 ($4096 \rightarrow 1024 \rightarrow 256$) 和位姿分支 ($4096 \rightarrow 256 \rightarrow 9$), 并用均方误差监督:

$$\mathcal{L}_{\text{world}} = \frac{1}{N} \sum_{k=1}^N m_k^{\text{obj}} \left(\|\hat{\mathbf{c}}_k^{t+1} - \mathbf{c}_k^{t+1}\|_2^2 + \lambda_p \|\hat{\mathbf{p}}_k^{t+1} - \mathbf{p}_k^{t+1}\|_2^2 \right); \quad (4)$$

机器人槽位不参与该损失, 因为其未来由正在生成的动作决定。动作头 h_ξ 读取 [ACT_Q] 隐藏状态, 是一个流匹配 MLP [3, 44], 用于在完整 16 步动作块上预测速度场 $\mathbf{v}_\xi$; 训练时最小化条件流匹配目标

$$\mathcal{L}_{\text{act}} = \mathbb{E}_{\tau, \epsilon} \|\mathbf{v}_\xi(\mathbf{A}_t^\tau, \tau, \mathbf{H}_{\text{ACT-Q}}) - (\mathbf{A}_t - \epsilon)\|_2^2, \quad \mathbf{A}_t^\tau = \tau \mathbf{A}_t + (1 - \tau) \epsilon, \quad (5)$$

其中 $\tau \sim \mathcal{U}(0, 1)$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。推理时, 动作块通过 4 步前向 Euler 积分在一次前向传播中解码, 避免了自回归动作解码器的块内误差累积 [9, 10]。辅助图像 VQ 头复用主干的 lm_head , 用加权交叉熵 $\mathcal{L}_{\text{vq}}$ 预测下一帧 VQ token, 不引入新参数。

3.5 训练目标

总训练损失把三个头项与两个来自先前对象中心 VLA 工作 [2, 26] 的辅助正则项结合起来:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{act}} + \lambda_w \mathcal{L}_{\text{world}} + \lambda_v \mathcal{L}_{\text{vq}} + \lambda_c \mathcal{L}_{\text{compose}} + \lambda_r \mathcal{L}_{\text{role}}. \quad (6)$$

$\mathcal{L}_{\text{compose}}$ 强制模型对随机干扰物置换和插入保持不变; $\mathcal{L}_{\text{role}}$ 在可用时使动作头注意力与从语言抽取的目标/参照标签对齐。四个权重 $\{\lambda_w, \lambda_v, \lambda_c, \lambda_r\}$ 是固定 (不可学习) 超参数, 取值为 $\{0.5, 0.04, 0.1, 0.05\}$; λ_c 在训练前 30% 从 0 线性升至最终值, λ_r 在训练前半段之后退火为 0。在冻结的 7B 槽位感知主干之上, 槽位适配器和预测头使用标准 LIBERO 演示进行对齐与微调, 得到约 $\sim 127\text{M}$ 个可训练参数 ($\{q, k, v, o, \text{gate}, \text{up}, \text{down}\}_{\text{proj}}$ 上 80M LoRA 参数, 预测头 47M); LIBERO-Plus 保留为分布外评估。伪代码见附录 A; 其余实现细节, 包括 token 化、槽位适配器与预测头架构、主干集成、序列模板、损失组件与增强、训练流程和超参数、推理延迟以及等变性证明, 见附录 B-G。

表 1: **LIBERO** 与 **SimplerEnv (WidowX, Visual Matching)** 比较。所有数值均为成功率 (%)。最佳结果加粗，第二名 加下划线。

方法	LIBERO					SimplerEnv WidowX (Visual Matching)				
	Spatial	Object	Goal	Long	平均	Spoon Towel	Carrot Plate	Stack Cube	Eggplant Basket	平均
视觉-语言-动作模型										
OpenVLA [32]	84.7	88.4	79.2	53.7	76.5	—	—	—	—	—
SpatialVLA [62]	88.2	89.9	78.6	55.5	78.1	16.7	25.0	29.2	100.0	42.7
π_0 [3]	96.8	98.8	95.8	85.2	94.2	—	—	—	—	—
$\pi_{0.5}$ [60]	<u>98.8</u>	98.2	98.0	92.4	96.9	—	—	—	—	—
InternVLA-M1 [14]	98.0	<u>99.0</u>	93.8	92.6	95.9	87.5	67.9	31.3	100.0	71.7
CogACT [39]	—	—	—	—	—	71.7	50.8	15.0	67.5	51.3
世界动作模型										
F1-VLA [52]	98.2	97.8	95.4	91.3	95.7	50.0	70.8	50.0	66.7	—
MemoryVLA [66]	98.4	98.4	96.4	93.4	96.5	75.0	75.0	37.5	100.0	71.9
VLA-JEPA [73]	96.2	99.6	97.2	95.8	<u>97.2</u>	75.0	70.8	12.5	70.8	57.3
CoWVLA [85]	97.2	97.8	94.6	92.8	95.6	79.2	66.7	<u>62.5</u>	95.8	<u>76.0</u>
ThinkAct [27]	88.3	91.4	87.1	70.9	84.4	58.3	37.5	8.7	70.8	43.8
VITA [53]	95.9	98.9	95.1	96.8	96.7	<u>84.2</u>	68.8	37.5	95.6	71.5
OA-WAM (本文)	98.9	<u>99.0</u>	97.4	<u>95.9</u>	97.8	83.0	<u>71.1</u>	65.0	98.2	79.3

4 实验

4.1 设置

本文在三个仿真基准上评估。**LIBERO** [45] 衡量四个标准任务套件 (Spatial / Object / Goal / Long) 上的分布内成功率。**SimplerEnv** (WidowX, Bridge 任务、Visual Matching) [40] 衡量相对于真实 WidowX 场景的仿真到真实视觉匹配。**LIBERO-Plus** [19] 在七个受控扰动轴上衡量鲁棒性: Camera、Robot init、Layout、Light、Background、Language、Sensor noise; 训练仅限标准 **LIBERO** 演示。所有报告数值均为三个随机种子的均值; 逐套件引用来源、置信区间计算和结果来源归因见附录 H。

4.2 主要结果

标准基准。 在 **LIBERO** 和 **SimplerEnv** 上 (表 1), **OA-WAM** 的平均成功率达到 97.8 和 79.3, 分别比最强先前基线高 +0.6% (**LIBERO** 上的 VLA-JEPA, 97.2) 和 +3.3% (**SimplerEnv** 上的 CoWVLA, 76.0)。因此, 槽位感知分解并未牺牲分布内精度, 这是后续鲁棒性比较的前提。

鲁棒性基准。 在 **LIBERO-Plus** 上 (表 2), **OA-WAM** 在与本文假设最一致的三个几何轴上取得新的 SOTA (Geo Avg 84.3, 比 $\pi_{0.5}$ 高 +4.8%): 这三个轴都保持目标物体身份不变, 同时几何重排场景, 正是仅地址路由发挥作用的区域。**OA-WAM** 在外观/语言轴上与 $\pi_{0.5}$ 的优势相当, 但在 Sensor Noise 上落后 -17.1%, 这是槽位提取失败 (光度失真破坏逐对象内容) 而不是策略阶段失败。表 4 确认, 几何轴收益来自基于地址的绑定, 而非额外容量。

4.3 消融研究

A1: 对象可寻址性隔离。 为隔离 OA 约束, 本文比较三个除 OA 之外完全相同的变体。它们共享训练流程、六路径 token 化、槽位适配器、世界/动作头、三个随机种子和评估协议, 只在两个开关上不同: 式 (3) 的仅地址键掩码 $\text{mask}_{\leq 32}$, 以及每层地址流重置钩子 (表 3)。**V0** (完整 **OA-WAM**) 开启二者; **V1** 关闭键掩码; **V2** 进一步关闭重置钩子。关键在于, **V2** 与 **V0** 使用完全相同的 SAM 3 + DINOv3 + Qwen3-VL 感知、槽位 token 化、主干权重和训练数据, 是判断几何轴收益来自重型感知栈还是 OA 约束的自然对照。**V0**→**V2** 在 LP camera 上损失 20.0%, LP avg 损失 7.7%, 说明几何轴效果主要来自 OA 约束本身, 而非感知前端。仅禁用键掩码 (**V0**→**V1**) 使 LP camera 下降 13.3%, LP robot 下降 18.2%, 而 **LIBERO** 只变

表 2: **LIBERO-Plus** 鲁棒性基准比较 (零样本, 仅在标准 **LIBERO** 上训练)。七个扰动轴 (Camera / Robot init / Layout / Light / Background / Language / Sensor noise) 上的成功率 (%)。 **Geo Avg** 表示 Camera/Robot/Layout 三个几何轴的均值 [19]。基线行来自 [94] 的零样本评估或各方法原始报告。最佳结果加粗, 第二名 加下划线。

方法	Cam	Robot	Layout	Geo Avg	Light	BG	Lang	Noise	平均
视觉-语言-动作模型									
OpenVLA-OFT [33]	56.4	31.9	74.2	54.2	88.7	93.3	79.5	75.8	69.6
π_0 [3]	13.8	6.0	68.9	29.6	85.0	81.4	58.8	79.0	53.6
$\pi_{0.5}$ [60]	75.4	77.5	85.7	<u>79.5</u>	96.9	94.6	85.6	<u>89.7</u>	85.7
ABot-M0 [87]	60.4	67.9	82.6	70.3	96.2	91.6	<u>86.4</u>	86.4	80.5
X-VLA [97]	23.4	89.7	71.8	61.6	88.2	96.0	75.7	62.7	71.4
AVA-VLA [83]	55.5	25.9	74.1	51.8	95.5	88.9	85.6	78.0	70.1
世界动作模型									
WorldVLA [10]	0.1	27.9	38.0	22.0	43.7	17.1	41.6	10.9	25.0
VLA-JEPA [73]	64.2	67.7	<u>83.9</u>	71.9	91.8	93.4	88.1	65.8	79.5
GE-Act [42]	60.7	77.0	80.2	72.6	95.8	86.0	77.4	90.9	80.3
HoloBrain-0 [43]	65.5	58.2	79.5	67.7	88.1	90.3	78.7	66.9	74.0
Cosmos-Policy [34]	<u>75.8</u>	63.3	82.2	73.8	<u>96.5</u>	88.9	81.7	92.7	82.2
OA-WAM (本文)	80.5	<u>89.6</u>	82.8	84.3	<u>96.5</u>	<u>95.9</u>	85.3	75.6	<u>83.9</u>
相对先前最佳的 Δ	+4.7	-0.1	-2.9	+4.8	-0.4	-0.1	-2.8	-17.1	-1.8




图 4: 主要结果。左: LIBERO-Plus 七个扰动轴的雷达图 (表 2); 右: SimplerEnv WidowX (Bridge) 逐任务成功率 (表 1)。OA-WAM 在几何 LIBERO-Plus 轴上达到新的 SOTA (Geo-Avg 84.3, 比 $\pi_{0.5}$ 高 +4.8%), 并在 SimplerEnv 上取得 79.3 平均成功率。

化 1.5%, 分布内漂移和几何 OOD 崩溃之间存在一个数量级差距。在 V1 基础上再移除重置钩子 (V1→V2) 会使交换绑定从 0.19 降到 0.06, 把剩余效果归因于每层地址流隔离。损伤集中在保持目标身份但几何重排场景的轴上, 与表 2 相互呼应, 呈现 OOD 特定归纳偏置而不是通用容量增益的非对称特征。




图 5: 机制诊断 (A1, A2)。 (a) LP-camera 成功率随相机偏移角 $\Delta\theta$ 的变化: V0 (完整 OA-WAM) 和 V1 (关闭掩码) 在分布内重合, 随着 $\Delta\theta$ 增大而分离。 (b) 来自 r_{1-4} 的角色查询注意力 (target/reference/tool/distractor) 在槽位类型上的分布, 在 300 个 LIBERO-Spatial episode 上取平均。 (c) A2 地址交换下的末端执行器轨迹: OA-WAM 向被交换目标偏转, 而整体式基线不会偏转 (余弦见表 4)。

表 3: A1: 隔离对象可寻址性约束。三个变体除仅地址键掩码 $\text{mask}_{\leq 32}$ (式 (3)) 和每层地址重置钩子外完全相同。A2 的交换绑定作为行为参考一并列出。

变体	K 掩码	重置钩子	LIBERO	LP camera	LP robot	LP avg	SimplerEnv	交换绑定 $\uparrow$
V2 (无 OA)	off	off	95.4	60.5	64.8	76.2	56.7	0.06
V1 (关闭掩码, 开启钩子)	off	on	96.3	67.2	71.4	80.8	64.0	0.19
V0 (完整 OA-WAM, 本文)	on	on	97.8	80.5	89.6	83.9	79.3	0.87

A2: 因果槽位干预。 A1 表明 OA 对 OOD 成功是必要的; A2 追问互补的机制问题: 训练后的策略在推理时是否确实通过地址子空间来路由目标选择? 本文交换语言绑定目标槽位与场景中另一槽位的地址, 保持其余输入固定, 并测量所得末端执行器残差轨迹与被交换目标方向之间的余弦对齐 (表 4)。OA-WAM 达到 0.87, 而八个整体式 VLA/WAM 基线均不超过 0.09。同一诊断也定位了本文设计空间中的绑定来源: 移除主干 OA 约束 (V1) 时, 尽管槽位感知头保持不变, 绑定降至 0.19; 在启用 OA 的情况下改用均值池化头, 绑定也降至 0.18。主干约束和可寻址读出必须同时存在。图 5 展示了相机偏移扫描、角色查询注意力和俯视轨迹偏转。

表 4: A2: 因果槽位干预 (交换绑定)。测试时交换语言绑定目标槽位与场景中另一槽位的地址, 其余输入固定; 指标为末端执行器残差轨迹与朝向被交换目标的位移方向之间的余弦对齐。

方法	交换绑定 $\uparrow$
OpenVLA [32]	0.04
π_0 [3]	0.05
$\pi_{0.5}$ [60]	0.05
OpenVLA-OFT [33]	0.06
WorldVLA [10]	0.09
VLA-JEPA [73]	0.07
Cosmos-Policy [34]	0.06
GE-Act [42]	0.07
OA-WAM (V1, 关闭掩码)	0.19
OA-WAM (均值池化头)	0.18
OA-WAM (完整, 本文)	0.87

5 结论

OA-WAM 使世界动作建模具备对象可寻址性: 一个槽位感知 7B 主干通过冻结的逐对象身份地址来路由跨槽位注意力。它在 LIBERO 和 SimplerEnv 上领先, 并在几何 LIBERO-Plus 轴上达到新的 SOTA (Geo Avg 比 $\pi_{0.5}$ 高 +4.8%); 该偏置也可验证: 交换绑定为 0.87, 而每个整体式基线均不超过 0.09, OA 隔离会特异性削弱几何轴而几乎不影响 LIBERO。这为构建在场景几何重排但目标身份保持不变时仍稳定的世界动作模型, 提供了一条可验证的设计路径。

局限性。 验证仅在仿真中完成, 报告的鲁棒性尚不能证明真实机器人部署可行。冻结 tokenizer 在小型反光、透明、遮挡或运动模糊物体上会失败, 导致 Sensor Noise 轴 -17.1% 的差距 (槽位提取而非策略失败; 附录 I)。干扰物一致性损失也假设目标/干扰物之间的耦合较弱。感知耗时约 ~ 95 ms/帧, 而主干 + 头约 ~ 5.6 ms (附录 G)。

参考文献

- [1] Shuai Bai, Yuxuan Cai, Ruizhe Chen, Keqin Chen, Xionghui Chen, Zesen Cheng, Lianghao Deng, Wei Ding, Chang Gao, Chunjiang Ge, et al. Qwen3-VL technical report. *arXiv preprint arXiv:2511.21631*, 2025.
- [2] Rokas Bendikis, Daniel Dijkman, Markus Peschl, Sanjay Haresh, and Pietro Mazzaglia. Focusing on what matters: Object-Agent-centric Tokenization for Vision Language Action models. *arXiv preprint arXiv:2509.23655*, 2025.
- [3] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A Vision-Language-Action flow model for general robot control. In *Robotics: Science and Systems (RSS)*, 2025. arXiv:2410.24164.
- [4] Aleksei Bochkovskii, Amael Delaunoy, Hugo Germain, Marcel Santos, Yichao Zhou, Stephan R. Richter, and Vladlen Koltun. Depth Pro: Sharp monocular metric depth in less than a second. *arXiv preprint arXiv:2410.02073*, 2024.
- [5] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. RT-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [6] Christopher P. Burgess, Loic Matthey, Nicholas Watters, Rishabh Kabra, Irina Higgins, Matt Botvinick, and Alexander Lerchner. MONet: Unsupervised scene decomposition and representation. *arXiv preprint arXiv:1901.11390*, 2019.
- [7] Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, Andrew Huang, et al. SAM 3: Segment Anything with concepts. *arXiv preprint arXiv:2511.16719*, 2025.
- [8] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021. arXiv:2104.14294.
- [9] Jun Cen, Siteng Huang, Yuqian Yuan, Kehan Li, Hangjie Yuan, Chaohui Yu, Yuming Jiang, Jiayan Guo, Xin Li, Hao Luo, et al. RynnVLA-002: A unified Vision-Language-Action and world model. *arXiv preprint arXiv:2511.17502*, 2025.
- [10] Jun Cen, Chaohui Yu, Hangjie Yuan, Yuming Jiang, Siteng Huang, Jiayan Guo, Xin Li, Yibing Song, Hao Luo, Fan Wang, Deli Zhao, and Hao Chen. WorldVLA: Towards autoregressive action world model. *arXiv preprint arXiv:2506.21539*, 2025.
- [11] Chameleon Team. Chameleon: Mixed-modal early-fusion foundation models. *arXiv preprint arXiv:2405.09818*, 2024.
- [12] Alexandre Chapin, Emmanuel Dellandréa, and Liming Chen. STORM: Slot-based task-aware object-centric representation for robotic manipulation. *arXiv preprint arXiv:2601.20381*, 2026.
- [13] Haonan Chen, Jingxiang Guo, Bangjun Wang, Tianrui Zhang, Xuchuan Huang, Boren Zheng, Yiwen Hou, Chenrui Tie, Jiajun Deng, and Lin Shao. Goal-VLA: Image-generative VLMs as object-centric world models empowering zero-shot robot manipulation. *arXiv preprint arXiv:2506.23919*, 2025.
- [14] Xinyi Chen, Yilun Chen, Yanwei Fu, Ning Gao, Jiaya Jia, et al. InternVLA-M1: A spatially guided vision-language-action framework for generalist robot policy. *arXiv preprint arXiv:2510.13778*, 2025.
- [15] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion Policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems (RSS)*, 2023. arXiv:2303.04137.
- [16] Yilun Du, Mengjiao Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2302.00111.
- [17] Gamaleldin F. Elsayed, Aravindh Mahendran, Sjoerd van Steenkiste, Klaus Greff, Michael C. Mozer, and Thomas Kipf. SAVi++: Towards end-to-end object-centric learning from real-world videos. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. arXiv:2206.07764.
- [18] Martin Engelcke, Adam R. Kosiorek, Oiwi Parker Jones, and Ingmar Posner. GENESIS: Generative scene inference and sampling with object-centric latent representations. In *International Conference on Learning Representations (ICLR)*, 2020. arXiv:1907.13052.

- [19] Senyu Fei, Siyin Wang, Junhao Shi, Zihao Dai, Jikun Cai, Pengfang Qian, Li Ji, Xinzhe He, Shiduo Zhang, Zhaoye Fei, et al. LIBERO-Plus: In-depth robustness analysis of Vision-Language-Action models. *arXiv preprint arXiv:2510.13626*, 2025.
- [20] Stefano Ferraro, Pietro Mazzaglia, Tim Verbelen, and Bart Dhoedt. FOCUS: Object-centric world models for robotics manipulation. *arXiv preprint arXiv:2307.02427*, 2023.
- [21] Jiahui Fu, Junyu Nan, Lingfeng Sun, Hongyu Li, Jianing Qian, Jennifer L. Barry, Kris Kitani, and George Konidaris. NovaPlan: Zero-shot long-horizon manipulation via closed-loop video language planning. *arXiv preprint arXiv:2602.20119*, 2026.
- [22] Klaus Greff, Raphael Lopez Kaufman, Rishabh Kabra, Nick Watters, Chris Burgess, Daniel Zoran, Loic Matthey, Matthew Botvinick, and Alexander Lerchner. Multi-object representation learning with iterative variational inference. In *International Conference on Machine Learning (ICML)*, 2019. arXiv:1903.00450.
- [23] Jianing Guo, Zhenhong Wu, Chang Tu, Yiyao Ma, Xiangqi Kong, Zhiqian Liu, Jiaming Ji, Shuning Zhang, Yuanpei Chen, Kai Chen, et al. On robustness of Vision-Language-Action model against multi-modal perturbations. *arXiv preprint arXiv:2510.00037*, 2025.
- [24] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models. *Nature*, 2025. arXiv:2301.04104.
- [25] Nicklas Hansen, Hao Su, and Xiaolong Wang. TD-MPC2: Scalable, robust world models for continuous control. In *International Conference on Learning Representations (ICLR)*, 2024. arXiv:2310.16828.
- [26] Taisei Hanyu, Nhat Chung, Huy Le, Toan Nguyen, Yuki Ikebe, Anthony Gunderman, Duy Ho Minh Nguyen, Khoa Vo, Tung Kieu, Kashu Yamazaki, et al. SlotVLA: Towards modeling of object-relation representations in robotic manipulation. *arXiv preprint arXiv:2511.06754*, 2025.
- [27] Chi-Pin Huang, Yueh-Hua Wu, Min-Hung Chen, Yu-Chiang Frank Wang, and Fu-En Yang. ThinkAct: Vision-language-action reasoning via reinforced visual latent planning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. arXiv:2507.16815.
- [28] Chia-Yu Hung, Qi Sun, Pengfei Hong, Amir Zadeh, Chuan Li, U-Xuan Tan, Navonil Majumder, and Soujanya Poria. NORA: A small open-sourced generalist vision language action model for embodied tasks. *arXiv preprint arXiv:2504.19854*, 2025.
- [29] Youngjoon Jeong, Junha Chun, Soonwoo Cha, and Taesup Kim. Object-centric world model for language-guided manipulation. *arXiv preprint arXiv:2503.06170*, 2025.
- [30] Yunfan Jiang, Agrim Gupta, Zichen Zhang, Guanzhi Wang, Yongqiang Dou, Yanjun Chen, Li Fei-Fei, Anima Anandkumar, Yuke Zhu, and Linxi Fan. VIMA: General robot manipulation with multimodal prompts. In *International Conference on Machine Learning (ICML)*, 2023. arXiv:2210.03094.
- [31] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *Robotics: Science and Systems (RSS)*, 2024. arXiv:2403.12945.
- [32] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. OpenVLA: An open-source Vision-Language-Action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [33] Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning Vision-Language-Action models: Optimizing speed and success. In *Robotics: Science and Systems (RSS)*, 2025. arXiv:2502.19645.
- [34] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, et al. Cosmos Policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv:2601.16163*, 2026.
- [35] Thomas Kipf, Gamaleldin F. Elsayed, Aravindh Mahendran, Austin Stone, Sara Sabour, Georg Heigold, Rico Jonschkowski, Alexey Dosovitskiy, and Klaus Greff. Conditional object-centric learning from video. In *International Conference on Learning Representations (ICLR)*, 2022. arXiv:2111.12594.
- [36] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, et al. Segment Anything. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023. arXiv:2304.02643.
- [37] Hugo Laurençon, Léo Tronchon, Matthieu Cord, and Victor Sanh. What matters when building vision-language models? *arXiv preprint arXiv:2405.02246*, 2024.

- [38] Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, et al. Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*, 2026.
- [39] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. CogACT: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024.
- [40] Xuanlin Li, Kyle Hsu, Jiayuan Gu, Karl Pertsch, Oier Mees, Homer Rich Walke, Chuyuan Fu, Ishikaa Lunawat, Isabel Sieh, Sean Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. In *Conference on Robot Learning (CoRL)*, 2024. arXiv:2405.05941.
- [41] Ying Li, Xiaobao Wei, Xiaowei Chi, Yuming Li, Zhongyu Zhao, Hao Wang, Ningning Ma, Ming Lu, and Shanghang Zhang. ManipDreamer: Boosting robotic manipulation world model with action tree and visual guidance. *arXiv preprint arXiv:2504.16464*, 2025.
- [42] Yue Liao, Pengfei Zhou, Siyuan Huang, Donglin Yang, Shengcong Chen, et al. Genie Envisioner: A unified world foundation platform for robotic manipulation. *arXiv preprint arXiv:2508.05635*, 2025.
- [43] Xuewu Lin, Tianwei Lin, Yun Du, Hongyu Xie, Yiwei Jin, Jiawei Li, Shijie Wu, Qingze Wang, Mengdi Li, Mengao Zhao, Ziang Li, Chaodong Huang, Hongzhe Bi, Lichao Huang, and Zhizhong Su. HoloBrain-0 technical report. *arXiv preprint arXiv:2602.12062*, 2026.
- [44] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2210.02747.
- [45] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2306.03310.
- [46] Dongyang Liu, Shitian Zhao, Le Zhuo, Weifeng Lin, Yi Xin, Xinyue Li, Qi Qin, Yu Qiao, Hongsheng Li, and Peng Gao. Lumina-mGPT: Illuminate flexible photorealistic text-to-image generation with multimodal generative pretraining. *arXiv preprint arXiv:2408.02657*, 2024.
- [47] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2304.08485.
- [48] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. RDT-1B: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.
- [49] Yuejiang Liu, Fan Feng, Lingjing Kong, Weifeng Lu, Jinzhou Tang, Kun Zhang, Kevin Murphy, Chelsea Finn, and Yilun Du. World action verifier: Self-improving world models via forward-inverse asymmetry. *arXiv preprint arXiv:2604.01985*, 2026.
- [50] Francesco Locatello, Dirk Weissenborn, Thomas Unterthiner, Aravindh Mahendran, Georg Heigold, Jakob Uszkoreit, Alexey Dosovitskiy, and Thomas Kipf. Object-centric learning with slot attention. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. arXiv:2006.15055.
- [51] Hao Luo, Wanpeng Zhang, Yicheng Feng, Sipeng Zheng, Haiweng Xu, Chaoyi Xu, Ziheng Xi, Yuhui Fu, and Zongqing Lu. Being-H0.7: A latent world-action model from egocentric videos. *arXiv preprint arXiv:2605.00078*, 2026.
- [52] Qi Lv, Weijie Kong, Hao Li, Jia Zeng, Zherui Qiu, et al. F1: A vision-language-action model bridging understanding and generation to actions. *arXiv preprint arXiv:2509.06951*, 2025.
- [53] Xiangkai Ma, Lekai Xing, Han Zhang, Wenzhong Li, and Sanglu Lu. Unifying perception and action: A hybrid-modality pipeline with implicit visual chain-of-thought for robotic action generation. *arXiv preprint arXiv:2511.19859*, 2025.
- [54] Malte Mosbach, Jan Niklas Ewertz, Angel Villar-Corrales, and Sven Behnke. SOLD: Slot object-centric latent dynamics models for relational manipulation learning from pixels. *arXiv preprint arXiv:2410.08822*, 2024.
- [55] Soroush Nasiriany, Abhiram Maddukuri, Lance Zhang, Adeet Parikh, Aaron Lo, Abhishek Joshi, Ajay Mandlekar, and Yuke Zhu. RoboCasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*, 2024.

- [56] NVIDIA GEAR Team. GR00T N1.5: An improved open foundation model for generalist humanoid robots. NVIDIA Research Blog, June 2025. https://research.nvidia.com/labs/gear/gr00t-n1_5/.
- [57] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. In *Robotics: Science and Systems (RSS)*, 2024. arXiv:2405.12213.
- [58] Open X-Embodiment Collaboration, Abby O’Neill, Abdul Rehman, Abhinav Gupta, Abhiram Madhukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, et al. Open X-Embodiment: Robotic learning datasets and RT-X models. *arXiv preprint arXiv:2310.08864*, 2023.
- [59] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. arXiv:2304.07193.
- [60] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}$: a Vision-Language-Action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [61] Wilbert Pumacay, Ishika Singh, Jiafei Duan, Ranjay Krishna, Jesse Thomason, and Dieter Fox. THE COLOSSEUM: A benchmark for evaluating generalization for robotic manipulation. *arXiv preprint arXiv:2402.08191*, 2024.
- [62] Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, Jiayuan Gu, Bin Zhao, Dong Wang, and Xuelong Li. SpatialVLA: Exploring spatial representations for Visual-Language-Action model. *arXiv preprint arXiv:2501.15830*, 2025.
- [63] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, 2021. arXiv:2103.00020.
- [64] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 2020. arXiv:1910.10683.
- [65] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, et al. SAM 2: Segment Anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [66] Hao Shi, Bin Xie, Yingfei Liu, Lin Sun, Fengrong Liu, et al. MemoryVLA: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [67] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. CLIPort: What and where pathways for robotic manipulation. In *Conference on Robot Learning (CoRL)*, 2021. arXiv:2109.12098.
- [68] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-Actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning (CoRL)*, 2022. arXiv:2209.05451.
- [69] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, et al. SmolVLA: A Vision-Language-Action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- [70] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, et al. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.
- [71] Gautam Singh, Yi-Fu Wu, and Sungjin Ahn. Simple unsupervised object-centric learning for complex and naturalistic videos. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. arXiv:2205.14065.
- [72] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World Guidance: World modeling in condition space for action generation. *arXiv preprint arXiv:2602.22010*, 2026.
- [73] Jingwen Sun, Wenyao Zhang, Zekun Qi, Shaojie Ren, Zezhi Liu, et al. VLA-JEPA: Enhancing vision-language-action model with latent world model. *arXiv preprint arXiv:2602.10098*, 2026.

- [74] Khoa Vo, Taisei Hanyu, Yuki Ikebe, Trong Thang Pham, Nhat Chung, Minh Nhat Vu, Duy Ho Minh Nguyen, Anh Nguyen, Anthony Gunderman, Chase Rainwater, and Ngan Le. Clutter-robust Vision-Language-Action models through object-centric and geometry grounding. *arXiv preprint arXiv:2512.22519*, 2025.
- [75] Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quan Vuong, Andre He, Vivek Myers, Kuan Fang, Chelsea Finn, and Sergey Levine. BridgeData V2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, 2023. arXiv:2308.12952.
- [76] Guodong Wang, Chenkai Zhang, Qingjie Liu, Jinjin Zhang, Jiancheng Cai, Junjie Liu, and Xinmin Liu. LIBERO-X: Robustness litmus for Vision-Language-Action models. *arXiv preprint arXiv:2602.06556*, 2026.
- [77] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. VGGT: Visual geometry grounded transformer. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. arXiv:2503.11651.
- [78] Junke Wang, Yi Jiang, Zehuan Yuan, Binyue Peng, Zuxuan Wu, and Yu-Gang Jiang. OmniTokenizer: A joint image-video tokenizer for visual generation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2406.09399.
- [79] Yuqi Wang, Xinghang Li, Wenxuan Wang, Junbo Zhang, Yingyan Li, Yuntao Chen, Xinlong Wang, and Zhaoxiang Zhang. Unified Vision-Language-Action model. *arXiv preprint arXiv:2506.19850*, 2025.
- [80] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. FoundationPose: Unified 6D pose estimation and tracking of novel objects. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. arXiv:2312.08344.
- [81] Ziyi Wu, Nikita Dvornik, Klaus Greff, Thomas Kipf, and Animesh Garg. SlotFormer: Unsupervised visual dynamics simulation with object-centric models. In *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2210.05861.
- [82] Ziyi Wu, Jingyu Hu, Wuyue Lu, Igor Gilitschenski, and Animesh Garg. SlotDiffusion: Object-centric generative modeling with diffusion models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023. arXiv:2305.11281.
- [83] Lei Xiao, Jifeng Li, Juntao Gao, Feiyang Ye, Yan Jin, Jingjing Qian, Jing Zhang, Yong Wu, and Xiaoyuan Yu. AVA-VLA: Improving Vision-Language-Action models with active visual attention. *arXiv preprint arXiv:2511.18960*, 2025.
- [84] Yuhan Xie, Yuping Yan, Yunqi Zhao, Handing Wang, and Yaochu Jin. STRONG-VLA: Decoupled robustness learning for Vision-Language-Action models under multimodal perturbations. *arXiv preprint arXiv:2604.10055*, 2026.
- [85] Fuxiang Yang, Donglin Di, Lulu Tang, Xuancheng Zhang, Lei Fan, et al. Chain of World: World model thinking in latent motion. *arXiv preprint arXiv:2603.03195*, 2026.
- [86] Jiazhi Yang, Kunyang Lin, Jinwei Li, Wencong Zhang, Tianwei Lin, Longyan Wu, Zhizhong Su, Hao Zhao, Ya-Qin Zhang, Li Chen, Ping Luo, Xiangyu Yue, and Hongyang Li. RISE: Self-improving robot policy with compositional world model. *arXiv preprint arXiv:2602.11075*, 2026.
- [87] Yandan Yang, Shuang Zeng, Tong Lin, Xinyuan Chang, Dekang Qi, et al. ABot-M0: VLA foundation model for robotic manipulation with action manifold learning. *arXiv preprint arXiv:2602.11236*, 2026.
- [88] Yue Yang, Shuo Cheng, Yu Fang, Homanga Bharadhwaj, Mingyu Ding, Gedas Bertasius, and Daniel Szafr. LiLo-VLA: Compositional long-horizon manipulation via linked object-centric policies. *arXiv preprint arXiv:2602.21531*, 2026.
- [89] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, et al. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.
- [90] Ge Yuan, Qiyuan Qiao, Jing Zhang, and Dong Xu. AdaWorldPolicy: World-model-driven diffusion policy with online adaptive learning for robotic manipulation. *arXiv preprint arXiv:2602.20057*, 2026.
- [91] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.

- [92] Andy Zeng, Pete Florence, Jonathan Tompson, Stefan Welker, Jonathan Chien, Maria Attarian, Travis Armstrong, Ivan Krasin, Dan Duong, Ayzaan Wahid, Vikas Sindhwani, and Johnny Lee. Transporter Networks: Rearranging the visual world for robotic manipulation. In *Conference on Robot Learning (CoRL)*, 2020. arXiv:2010.14406.
- [93] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023. arXiv:2303.15343.
- [94] Zhanguang Zhang, Zhiyuan Li, Behnam Rahmati, Rui Heng Yang, Yintao Ma, Amir Rasouli, Sajjad Pakdamansavoji, Yangzheng Wu, Lingfeng Zhang, Tongtong Cao, Feng Wen, Xinyu Wang, Xingyue Quan, and Yingxue Zhang. Do world action models generalize better than VLAs? A robustness study. *arXiv preprint arXiv:2603.22078*, 2026.
- [95] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. CoT-VLA: Visual chain-of-thought reasoning for Vision-Language-Action models. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. arXiv:2503.22020.
- [96] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems (RSS)*, 2023. arXiv:2304.13705.
- [97] Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, et al. X-VLA: Soft-prompted transformer as scalable cross-embodiment Vision-Language-Action model. *arXiv preprint arXiv:2510.10274*, 2025.
- [98] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, and Chuang Gan. RoboDreamer: Learning compositional world models for robot imagination. In *International Conference on Machine Learning (ICML)*, 2024. arXiv:2404.12377.
- [99] Xueyang Zhou, Yangming Xu, Guiyao Tie, Yongchao Chen, Guowen Zhang, Duanfeng Chu, Pan Zhou, and Lichao Sun. LIBERO-PRO: Towards robust and fair evaluation of Vision-Language-Action models beyond memorization. *arXiv preprint arXiv:2510.03827*, 2025.
- [100] Yi Zhou, Connelly Barnes, Jingwan Lu, Jimei Yang, and Hao Li. On the continuity of rotation representations in neural networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019. arXiv:1812.07035.
- [101] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. *arXiv preprint arXiv:2504.02792*, 2025.
- [102] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. RT-2: Vision-Language-Action models transfer web knowledge to robotic control. In *Conference on Robot Learning (CoRL)*, 2023. arXiv:2307.15818.

A 伪代码

算法 1 给出时刻 t 的一次闭环推理步骤，算法 2 给出一次 Stage-II 梯度更新。二者共享通过槽位感知主干的相同前向计算，只在头部输出（Euler 积分动作采样 vs. 流匹配损失）以及前向后的训练更新上不同。符号与正文一致。

算法 1 OA-WAM 在时刻 t 的推理步骤。

输入： 观测 $(\mathbf{I}_t, \mathbf{q}_t, \ell, \mathbf{a}_{<t})$ ，训练好的 θ ，episode 缓存的 $\{\mathbf{addr}_k\}$ （在 $t=0$ 计算）。

感知 — 冻结；每帧使用 SAM3 / DINOv3 / VQ-GAN；Qwen3-VL 在 $t=0$ 之后缓存。

- 1: $\{P\} \leftarrow \text{QWEN3-VL}(\ell)$
- 2: $\{M_k^t\} \leftarrow \text{SAM3}(\mathbf{I}_t, \{P\})$
- 3: $\mathbf{V}_t \leftarrow \text{VQ-GAN}(\mathbf{I}_t)$
- 4: $\mathbf{f}_k^t \leftarrow \text{DINOv3}(\mathbf{I}_t, M_k^t)$
- 5: $\mathbf{raw}_k^t \leftarrow [\mathbf{f}_k^t, \mathbf{p}_k^t, \ell_k, \text{shape}_k]$

序列构造。

- 6: **if** $t=0$ **then**
- 7: $\mathbf{addr}_k \leftarrow f_{\text{addr}}([\ell_k \parallel \mathbf{f}_k^0])$
- 8: **end if**
- 9: $\mathbf{cnt}_k^t \leftarrow f_{\text{cnt}}(\mathbf{raw}_k^t)$
- 10: $\mathbf{e}_k^t \leftarrow f_{\phi}([\mathbf{addr}_k \parallel \mathbf{cnt}_k^t \parallel \pi^t \parallel \rho_k])$
- 11: $\mathbf{E} \leftarrow \text{MASKED_SCATTER}(\text{embed_tokens}(\mathbf{x}_{1:L}), \{\mathbf{e}_k^t\})$
- 12: 构建 token-type 向量 τ 和块因果掩码 $\mathbf{M}$

槽位感知主干 — 每层在槽位位置应用式 (3) 并重置地址流。

- 13: $\mathbf{H} \leftarrow \text{SLOT-AWARE-TRUNK}_{\theta}(\mathbf{E}, \tau, \mathbf{M}; \{\mathbf{addr}_k\})$

头部读出。

- 14: $\hat{\mathbf{c}}_k^{t+1}, \hat{\mathbf{p}}_k^{t+1} \leftarrow h_{\psi}(\mathbf{H}_{\text{slot}})$ ▷ 世界头，式 (4)
- 15: $\mathbf{A}_t \leftarrow \text{EULER}_4(h_{\xi}; \mathbf{H}_{\text{ACT-Q}})$ ▷ 流匹配采样，式 (7)
- 16: **返回** $\mathbf{A}_t, \hat{\mathcal{S}}_{t+1} = \{(\hat{\mathbf{c}}_k^{t+1}, \hat{\mathbf{p}}_k^{t+1})\}_k$

算法 2 OA-WAM Stage-II 训练步骤（一个 mini-batch）。

输入： 演示 $(\mathbf{I}_t, \mathbf{q}_t, \ell, \mathbf{a}_{<t})$ 及目标 $\mathbf{A}_t^*, \mathbf{c}_k^{t+1*}, \mathbf{p}_k^{t+1*}, \mathbf{V}_{1:T}^*$ ；可训练参数 $\theta = \{\phi, \psi, \xi, \text{LoRA}\}$ 。

- 1: 运行算法 1 中的感知、序列构造和槽位感知主干模块，得到 $\mathbf{H}$
- 2: $\hat{\mathbf{c}}_k^{t+1}, \hat{\mathbf{p}}_k^{t+1} \leftarrow h_{\psi}(\mathbf{H}_{\text{slot}})$ ▷ 与推理相同的世界头前向

损失组装。

- 3: $\mathcal{L}_{\text{world}} \leftarrow \sum_k m_k^{\text{obj}} (\|\hat{\mathbf{c}}_k^{t+1} - \mathbf{c}_k^{t+1*}\|^2 + \lambda_p \|\hat{\mathbf{p}}_k^{t+1} - \mathbf{p}_k^{t+1*}\|^2)$
- 4: 采样 $\tau \sim \mathcal{U}(0, 1)$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 5: $\mathcal{L}_{\text{act}} \leftarrow \|\mathbf{v}_{\xi}(\tau \mathbf{A}_t^* + (1 - \tau)\epsilon, \tau, \mathbf{H}_{\text{ACT-Q}}) - (\mathbf{A}_t^* - \epsilon)\|^2$ ▷ 条件流匹配
- 6: $\mathcal{L}_{\text{vq}} \leftarrow \text{WEIGHTEDCE}(\text{lm_head}(\mathbf{H}_{\text{next-VQ}}), \mathbf{V}_{1:T}^*)$
- 7: $\mathcal{L}_{\text{compose}} \leftarrow \text{INVARIANCELoss}(\alpha, \mathbf{A}_t; \text{DISTRACTORAUG})$ ▷ 置换 ∪ 插入干扰物
- 8: $\mathcal{L}_{\text{role}} \leftarrow \text{KL}(\alpha_{0,1}, \text{onehot}(\text{target}, \text{ref}))$ ，若有标签且 $\text{step} < 50\text{k}$ ，否则为 0
- 9: $\mathcal{L} \leftarrow \mathcal{L}_{\text{act}} + 0.5 \mathcal{L}_{\text{world}} + 0.04 \mathcal{L}_{\text{vq}} + \eta_{\text{cmp}} \mathcal{L}_{\text{compose}} + 0.05 \mathcal{L}_{\text{role}}$

优化器步骤。

- 10: $\mathcal{L}.\text{BACKWARD}()$ ；将梯度裁剪到 1.0；AdamW 更新 θ ；以衰减 0.999 更新 EMA。

B 六路径 token 化与数据预处理

本附录说明原始演示如何加载与预处理，以及所得观测如何转换为主干使用的六条 token 路径。首先描述预处理，因为驱动 Stage II 的缓存感知特征和量化表都是下述选择的确定性函数。

演示加载与逐模态预处理

演示来源。 LIBERO 为每个任务套件提供标准 .hdf5 演示文件（Spatial、Object、Goal、Long；每个套件 10 个任务 × 每任务 50 条演示，20 Hz 仿真器）。对每条演示，读取第三人称和腕部视角 RGB 帧、7 维末端执行器状态 $(x, y, z, \text{roll}, \text{pitch}, \text{yaw}, \text{gripper})$ 、7 维环境动作 $(\Delta x, \Delta y, \Delta z, \Delta \text{roll}, \Delta \text{pitch}, \Delta \text{yaw},$

夹爪命令)以及自然语言指令。SimplerEnv WidowX (Bridge) 使用官方仿真器的 RGB / EE-pose / 语言字段; 不加入基准特定预处理。

图像预处理。 RGB 帧通过双线性插值调整为 256×256 , 并缩放到 $[0, 1]$ 。每个演示中的每帧只前向一次冻结感知栈 (Path I-A VQ-GAN, Path I-B SAM 3 + DINOv3); 得到的 token 和逐槽位特征缓存到磁盘, 在不同阶段或随机种子间不再重复计算。本文不使用颜色抖动、随机裁剪或其他 RGB 增强。唯一影响 Stage II 训练的数据增强, 是附录 F 中的槽位级干扰物置换/插入; 它作用于已经 token 化的槽位嵌入, 而非原始 RGB。

动作归一化。 前六个动作维度 ($\Delta x, \Delta y, \Delta z$ 和三个旋转增量) 保持在增量空间中, 按 LIBERO 训练划分的每维 1st/99th 百分位裁剪, 再线性缩放到 $[-1, 1]$ 。第七个 (夹爪) 维度根据演示的夹爪命令二值化为 $\{-1, +1\}$ (打开/闭合)。归一化后的 7 维动作堆叠为 16 步动作块 $\mathbf{A}_t^* \in \mathbb{R}^{16 \times 7}$, 作为流匹配头的监督目标; Path A-d 中的离散历史动作表示使用同一 $[-1, 1]$ 范围, 并对每个维度均匀量化为 256 桶。量化参数只在 LIBERO 标准划分上拟合 (不使用 LIBERO-Plus episode), 并在所有任务套件中共享。

状态预处理。 7-DoF 末端执行器位姿 $\mathbf{q}_t$ 输入 Path S, 其中每个维度均匀离散为 256 桶, 并映射到一段连续的保留词表 token。槽位向量中的 9 维逐对象位姿 $\mathbf{p}_k^t$ 拼接工作空间归一化位置 $[-1, 1]^3$ 与 $[100]$ 的 6 维连续旋转参数化, 后者由仿真器四元数真值计算。

语言预处理。 指令字符串从演示元数据读取, 并原样传入 Qwen3-VL-4B (Path T1) 和 Chameleon 的 BPE tokenizer (Path T2)。观测到的 LIBERO 指令最大 BPE 长度为 38 个 token; 不使用任何 prompt 模板或 chain-of-thought 脚手架。

帧采样与分块。 每个训练步骤均匀随机采样一条演示和一个 pivot 索引 t 。随后组装 $T = 4$ 个历史观测 $\mathbf{I}_{t-T+1:t}$ (当 $t < T - 1$ 时用初始帧左填充)、历史动作窗口 $\mathbf{a}_{t-T+1:t-1}$, 以及 16 步动作块目标 $\mathbf{a}_{t:t+15}$ (超出演示长度时用终止动作右填充, 并从损失中掩蔽)。填充掩码是显式张量, 会传播到所有下游损失和增强, 因此 episode 边界不会泄漏到逐步梯度中。

训练 / 测试划分。 Stage II 微调数据严格等于 LIBERO 标准演示; 没有任何 LIBERO-Plus 扰动因子 (layout、background、light、camera、robot init、language paraphrase、sensor noise) 出现在任何训练阶段。Stage 0 Web 图文混合是 Chameleon 已发布混合数据的去重子集; Stage 0 机器人混合 (Open X-Embodiment、DROID、RoboCasa、Bridge V2; 附录 G) 不包含 LIBERO 测试演示, 也不包含表 I 所用的 SimplerEnv WidowX (Bridge) episode。基准与预训练之间的分离在端到端流程中保持不变。

六路径 token 化

冻结感知对每条演示离线运行一次并缓存。下面总结六条 token 路径; 记号与正文一致。

Path T1 (Qwen3-VL 名词短语解析)。 将指令 ℓ 与第一帧观测一起输入 Qwen3-VL-4B [1]; 模型输出 JSON 格式的名词短语列表 (如 ["red mug", "white tray"]) 和关系图 (如 on(target, reference))。这些短语只作为 Path I-B 中 SAM 3 的文本提示, 不进入主干。缓存输出大小: 每条演示 < 1 KB。

Path T2 (BPE 文本 token)。 ℓ 由 Chameleon 的 BPE tokenizer [11] (词表大小 65,536) token 化, 并通过主干标准 embed_tokens 表嵌入。平均长度约为每条 LIBERO 指令 ~ 30 个 BPE token。

Path I-A (Chameleon VQ-GAN 图像码)。 每个输入视图调整到 256×256 , 并由 Chameleon 冻结 VQ-GAN (16×16 patch 网格, 8192 项码本) 编码为 256 个离散码。这些码占据 Chameleon 词表中的 ID 3-8194, 并像文本一样通过同一个 embed_tokens 表嵌入。第三人称和腕部视图均被编码; 默认配置中, 为限制长度, 输入序列仅保留第三人称视图的 VQ 码, 腕部视图只通过 Path I-B 贡献信息 (附录 G 的消融报告双视角变体)。

Path I-B (SAM 3 + DINOv3 + 位姿对象槽位)。 SAM 3 [7] 使用 Path T1 的每个短语作为提示, 并额外运行自动模式以给未提及干扰物提出候选掩码; 两组掩码按 IoU > 0.5 和 DINOv3 余弦相似度 > 0.9 去重。DINOv3 ViT-L/16 [70] 为每个槽位产生掩码池化特征 $\mathbf{f}_k^t \in \mathbb{R}^{1024}$, 再通过线性映射投影到 $\mathbb{R}^{256}$ 。9 维位姿向量 $\mathbf{p}_k^t$ 包含 3 维位置和 6 维连续旋转 $[100]$ 。标签嵌入 $\ell_k \in \mathbb{R}^{256}$ 是查询 SAM 3 的名词短语的平均 T5 编码 [64] (或自动发现干扰物的可学习 "unknown" token)。掩码形状描述符是 15 维拼接, 包含归一化质心、边界框、二阶矩、面积和凸性; 四部分拼接得到原始槽位向量 $\mathbf{raw}_k^t \in \mathbb{R}^{540}$ 。最大对象槽位数为 $N_{\max} = 16$; 机器人始终为槽位 0 且始终有效; 填充槽位在所有下游位置 (注意力、损失、增强、指标) 显式掩蔽, 因此表现集合等变性能不会被填充泄漏破坏。单帧感知在单张 A100 上耗时约 ~ 138 ms (73 ms SAM 3 + 22 ms DINOv3 + 43 ms Qwen3-VL), 训练期间完全离线摊销。真实部署时, 仿真器位姿替换为基于 Depth Pro 或 VGGT 特征的深度辅助估计, 以及 FoundationPose [4, 77, 80] 等 6D 位姿跟踪器; 这不是主要实证声明的一部分。

Path S (本体感知状态 token)。 7-DoF 末端执行器位姿加夹爪 $\mathbf{q}_t \in \mathbb{R}^7$ 在每维均匀离散为 256 桶, 并映射到未使用的 Chameleon 保留词表槽位的连续区间 (`<reserved15500>`–`<reserved16000>`), 因此不需要调整 `embed_tokens` 大小。

Path A-d (历史动作离散 token)。 每个历史动作 $\mathbf{a}_{t'}$ ($t' < t$) 以相同方式离散到 `<action>` 词表范围 (`<reserved10000>`–`<reserved15004>`)。待预测块的动作 token 不放入输入序列; 它们由流匹配头从 `[ACT_Q]` 解码。

C 槽位适配器、序列模板与槽位感知主干

本附录汇总将原始槽位特征转为主干 token 并处理它们的三个组件: (i) 槽位适配器, 将每个槽位的原始向量映射到主干的 4096 维嵌入空间; (ii) 统一序列模板, 在其中槽位嵌入被 `scatter` 到 Chameleon 词表流; (iii) 在每一层强制 OA 约束的槽位感知主干变体。

槽位适配器 f_ϕ

槽位适配器 $f_\phi: \mathbb{R}^{320} \rightarrow \mathbb{R}^{4096}$ 是一个带 LayerNorm 和 GELU 的两层 MLP:

$$f_\phi(\mathbf{s}) = W_2 \sigma(W_1 \text{LN}(\mathbf{s})), \quad W_1 \in \mathbb{R}^{4096 \times 320}, W_2 \in \mathbb{R}^{4096 \times 4096},$$

其中 σ 为 GELU 激活。产生 `addrk` 和 `cntkt` 的两个组件 MLP 同样是简单前馈网络: $f_{\text{addr}}: \mathbb{R}^{512} \rightarrow \mathbb{R}^{128} \rightarrow \mathbb{R}^{32}$ (输入 $[\ell_k \| \mathbf{f}_k^{(0)}]$), 以及 $f_{\text{cnt}}: \mathbb{R}^{540} \rightarrow \mathbb{R}^{512} \rightarrow \mathbb{R}^{256}$ 。时间位置编码 $\boldsymbol{\pi}^t \in \mathbb{R}^{16}$ 为帧索引 t 的正弦嵌入; 角色位置编码 $\boldsymbol{\rho}_k \in \mathbb{R}^{16}$ 是三类角色 (`robot, object, padding`) 的可学习查表。总参数量: f_ϕ 为 18.0M, $f_{\text{addr}} + f_{\text{cnt}}$ 为 0.4M。

序列模板与特殊 token

SEQUENCECONSTRUCTION 阶段组装的完整序列模板为

$$[\text{BOS}; \mathbf{x}^{T2}; \mathbf{x}^S; [\text{FBOS}; \mathbf{x}_t^{\text{I-A}}; \text{SBOS}; \mathbf{x}_t^{\text{I-B}}; \text{SEOS}; \mathbf{x}_t^{\text{A-d}}; \text{FEOS}]_{t=0}^{T-1}; [\text{ACT_Q}]],$$

其中每个帧组 G_t 包含 256 个图像 VQ 码 (Path I-A)、 $N+1$ 个槽位嵌入 (Path I-B, 经 `masked_scatter` 插入到 `<slot>` 占位位置), 以及 7 个离散动作 token (Path A-d, 仅在 $t < T-1$ 时存在)。当历史帧数 $T=4$ 、槽位数 $N+1=17$ 且使用单个图像视图时, 总序列长度为 $L \approx 1200$ token (位于 Chameleon 的 4096 位置窗口内)。

词表增补。 本文复用六个未使用的 Chameleon 保留 ID 作为特殊标记, 从而避免调整 `embed_tokens` 或 `lm_head` 大小:

符号	保留 token	作用
<code><slot></code>	<code><reserved16500></code>	槽位嵌入的 <code>masked_scatter</code> 占位符
<code>SBOS/SEOS</code>	<code><reserved16501/16502></code>	帧组内槽位块的起止标记
<code>FBOS/FEOS</code>	<code><reserved16503/16504></code>	帧组起止标记
<code>[ACT_Q]</code>	<code><reserved16505></code>	序列末端的可学习动作查询

Token-type 张量。 与输入 ID 一同构建平行张量 $\boldsymbol{\tau} \in \{\text{TEXT}, \text{VQ}, \text{SLOT}, \text{STATE}, \text{ACTION}, \text{SPECIAL}\}^L$ 。槽位感知注意力用它识别槽位位置, 预测头读出器用它识别世界预测和动作预测位置。

主干与槽位嵌入注入

主干规格。 主干是 Chameleon 风格多模态自回归 Transformer [11], 形状参数与 Lumina-mGPT-7B-768 [46] 相同: 32 个 Transformer 层、隐藏维度 4096、32 个注意力头且无 GQA、FFN 大小 11008 (SwiGLU)、词表 65536、最大位置 4096、RoPE $\theta=10000$ 。总参数量约 ~ 7.0 B。本文不导入机器人策略 checkpoint: 权重从公开发布的 Chameleon-7B base (多模态语言模型, 而非 VLA) 热启动, 然后在 Stage 0 中由本文从头完整重训, 并从第一步开始施加 OA 约束 (见附录 G 的 Stage 0)。OA-WAM 特有模块, 即槽位适配器 f_ϕ 、世界头 h_ψ 、流匹配动作头 h_ξ 和地址流重置钩子, 只在后预训练阶段引入, 不存在于任何先前 checkpoint 中。

槽位嵌入注入。 槽位嵌入通过 LLaVA 风格的 `masked_scatter` 模式 [37, 47] 进入主干: 先对输入 ID 序列运行 `embed_tokens` 得到 $(B, L, 4096)$ 张量, 构建标记 `<slot>` 占位位置的布尔掩码, 再用槽位适配器 f_ϕ 输出的逐槽位表示 (在 $(B, T(N+1))$ 轴上展平) 原地覆盖这些位置。所得张量与 token-type

张量和块因果掩码一起，通过 `inputs_embeds` 参数送入主干。关键在于，`embed_tokens` 与 `lm_head` 在三个训练阶段中从不调整大小：六个新特殊 token 都复用已有保留词表槽位，因此主干输出投影（辅助 VQ 头使用的 `lm_head`）保留 Stage-0 预训练得到的权重。补充材料提供参考实现。

每层 OA 约束

作为模块变体的槽位感知注意力。 每个 Transformer 层使用标准自注意力模块的槽位感知变体。该变体只重写前向路径：查询和值完全按照基础层投影；对于键，从 `token-type` 张量读取布尔槽位掩码，在投影前将残差流中槽位类型行的前 32 维之外坐标置零，然后应用 W_K 。非槽位位置使用标准自注意力路径，不进行掩码干预；OA 约束纯粹发生在槽位类型位置。四个投影矩阵 W_Q, W_K, W_V, W_O 是完整精度的 4096×4096 张量，并在整个 Stage 0 中从热启动的 Chameleon-7B 初始化继续训练；OA 掩码本身不引入额外参数（该掩码是不可学习的、按维度索引的选择）。

槽位 token 的帧内位置共享。 为保持帧内对象槽位的置换等变性，本文覆盖 Chameleon 默认的顺序 `position_ids`：在每个帧组 G_t 中，所有 $N+1$ 个槽位 token 共享单一 RoPE 位置索引 p_t （即 G_t 的起始位置）。非槽位 token（文本、VQ、动作、特殊 token）保持原始顺序位置。在这一构造下，对任意槽位行置换 Π ，槽位块满足 $\text{RoPE}(p_t)\Pi\mathbf{X} = \Pi\text{RoPE}(p_t)\mathbf{X}$ ，因此跨槽位注意力 $\text{logit}(\text{RoPE}(p_t)\mathbf{Q}_i, \text{RoPE}(p_t)\mathbf{K}_j) = \langle \mathbf{Q}_i, \mathbf{K}_j \rangle e^{i\theta(p_t, p_t)}$ 只依赖槽位内容（以及经过 OA 掩蔽的键地址子向量），而不依赖 G_t 中的槽位索引。消融中可以看到该效果：若把帧内共享替换为槽位位置上的默认顺序 RoPE，表 6 的置换 KL 从 0.04 升至 0.13，LP layout 相对默认 OA-WAM 配置下降约 4 点。帧内共享通过显式 `position_ids` 张量实现，并与 `inputs_embeds` 一同传入，不增加参数。

地址流重置钩子。 若干预，残差流最终会把内容混入前 32 维，随后式 (3) 不再保证仅地址路由。本文通过在每个 ChameleonDecoderLayer 上注册前向后钩子恢复不变量：在槽位类型位置，用缓存身份地址 addr_k 覆盖输出前 32 个坐标。该缓存由槽位适配器在每个 episode 中计算一次，并位于 autograd 图之外，因此钩子每层每次前向只需写入约 $\sim 64\text{KB}$ 张量（32 层合计约 $\sim 2\text{MB}$ ），对运行时几乎无影响。

地址的梯度流。 由于缓存 addr_k 位于 autograd 图之外，重置钩子在每一层对地址子向量起到梯度停止作用：任务特定信号无法通过主干残差流反传入 addr 。这是有意设计而非限制。 addr 编码稳定对象身份，应该只由语言标签 ℓ_k 和初始 DINOv3 特征 $\mathbf{f}_k^{(0)}$ 决定，并由 f_{addr} 在每个 episode 中计算一次。槽位适配器 f_ϕ （以及经由它的 f_{addr} ）仅通过输入层槽位嵌入 $\mathbf{e}_k = f_\phi([\text{addr}_k \parallel \text{cnt}_k^t \parallel \pi^t \parallel \rho_k])$ 接收梯度；这已经足够，因为 addr 的作用是身份寻址，而非任务条件绑定。任务条件学习集中在查询/值投影和残差内容流中。

32 维地址子空间的路由容量。 在余弦相似度下，32 维单位超球面在分离角 $\geq 0.05\text{rad}$ 时大约可容纳 ~ 1000 个两两分离方向（球面 packing 近似）。LIBERO 场景最多包含 16 个物体；LIBERO-Plus 在 layout-shift 下最多包含 24 个。Stage 0 期间，单帧中观测到的最大同时活跃地址数为 27，均值为 4.6，因此路由容量利用率始终 $\leq 3\%$ 。32 维硬限制不会成为本文关注尺度下的对象区分瓶颈。

注意力组织

注意力掩码模式。 在注意力内部的 OA 约束之上，本文根据 `token-type` 张量构建四个正交掩码层：(i) 帧组间块因果： G_t 中的 token 可关注 $G_0, \dots, G_t$ 中所有 token，但不能关注未来组；(ii) 帧组内 $\text{slot} \leftrightarrow \text{slot}$ 双向：同一 G_t 中任意槽位 token 可相互关注（置换等变性所必需）；(iii) 帧组内 $\text{slot} \rightarrow \text{VQ} \rightarrow \text{action}$ 单向： G_t 中的动作 token 可关注槽位/VQ token，但反向不允许，使世界侧隐藏状态不被其 grounding 的动作污染；(iv) $[\text{ACT}_Q]$ 可见全部：末尾查询 token 可关注所有先前位置。填充槽位位置被排除为可被关注对象（列为 $-\infty$ ），且不参与损失或增强。由于流匹配天然并行，本文不需要 [9, 10] 的块内动作掩码（第 3.4 节）。

可选 SE(3) 相对几何偏置。 仅对 $\text{slot} \leftrightarrow \text{slot}$ 注意力对，本文向注意力 logit 添加可学习偏置 $\phi_h(\mathbf{G}_{ij})$ ，其中 $\mathbf{G}_{ij}$ 存储槽位 i 与 j 之间的相对 SE(3) 变换（ $\mathbb{R}^3$ 平移加 $\mathbb{R}^3$ 轴角，共 6 个标量）， ϕ_h 是为每个 head 产生一个偏置的小型 MLP。该偏置不影响非槽位注意力对，默认开启（每层参数量约 $\sim 2\text{K}$ ）。

D 预测头架构

世界头 h_ψ 。 两个独立 MLP 读取逐槽位隐藏状态。内容头为 $\text{LN} \rightarrow \text{Linear}_{4096 \rightarrow 1024} \rightarrow \text{GELU} \rightarrow \text{Linear}_{1024 \rightarrow 256}$ ；位姿头为 $\text{LN} \rightarrow \text{Linear}_{4096 \rightarrow 256} \rightarrow \text{GELU} \rightarrow \text{Linear}_{256 \rightarrow 9}$ 。机器人槽位通过式 (4) 中的掩码 $m_k^{\text{obj}} \in \{0, 1\}$ 从监督中排除；填充槽位也被掩蔽。总参数量：5.4M。

动作头 h_ξ (流匹配 MLP)。 条件向量是 $[\text{ACT}_Q]$ 处主干隐藏状态的线性投影， $\mathbf{c} = W_c \mathbf{H}_{\text{ACT}_Q} \in \mathbb{R}^{1024}$ 。流 MLP 本身是一个 8 块残差网络，输入为 $\mathbf{c}$ 、展平的当前噪声动作块 $\mathbf{A}_t^\tau \in \mathbb{R}^{16 \times 7}$ 以及 τ 的 128 维正弦

嵌入的拼接；输出为预测速度 $\mathbf{v}_\xi \in \mathbb{R}^{16 \times 7}$ 。每个块为 $\text{LN} \rightarrow \text{Linear}_{1024 \rightarrow 1024} \rightarrow \text{GELU} \rightarrow \text{Linear}_{1024 \rightarrow 1024}$ ，带残差连接。推理采样采用下方式 (7) 的 4 步前向 Euler 积分；消融中发现（附录 G），从 4 步增加到 8 步对 LIBERO 成功率的影响小于 0.3%。总参数量约 $\sim 22\text{M}$ (W_c 4.2M；输入投影 1.3M；八个残差块 16.8M；输出投影 0.1M)。角色损失正则器使用的可选逐步软槽位分配 $\alpha \in \mathbb{R}^{16 \times (N+1)}$ 由槽位 token 位置上的辅助注意力层产生，额外增加 1.2M 参数。

辅助图像 VQ 头。 Stage II 中复用 Stage 0 产生的预训练 $\text{lm_head} \in \mathbb{R}^{65536 \times 4096}$ ，不作修改。下一帧 VQ 块通过 teacher forcing 追加，并在 next-VQ 位置计算加权交叉熵：图像 VQ 词表范围 (ID 3–8194) 的 token 权重为 0.04，其他位置权重为 1.0。这避免 8192 类 CE 损失主导梯度范数，同时仍保留 Stage-0 图像生成目标的价值，且不增加参数。推理时禁用该头，因为动作策略不使用下一帧 VQ token。

推理时 Euler 步。 给定条件向量 $\mathbf{c} = W_c \mathbf{H}_{\text{act-Q}}$ 和初始 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，动作块按

$$\mathbf{A}_t^{\tau+\Delta\tau} = \mathbf{A}_t^\tau + \Delta\tau \cdot \mathbf{v}_\xi(\mathbf{A}_t^\tau, \tau, \mathbf{c}), \quad \Delta\tau = 1/4, \quad (7)$$

解码，返回 $\mathbf{A}_t = \mathbf{A}_t^1$ 。单张 A100 上总推理开销约 $\sim 10\text{ms}$ /动作块，主要来自四次 22M 参数 MLP 前向。

逐模块参数统计。 OA-WAM 所有阶段的总参数如下：

模块	参数量	训练阶段
Chameleon-7B 主干 (含 OA 掩码 + 重置钩子)	$\sim 7000\text{M}$	Stage 0 (完整预训练); Stage II 冻结
槽位适配器 f_ϕ	18.0 M	Stage I, Stage II 继续训练
$f_{\text{addr}} + f_{\text{cnt}}$	0.4 M	Stage I, Stage II 继续训练
世界头 h_ψ	5.4 M	Stage I, Stage II 继续训练
动作头 h_ξ (流匹配 MLP)	22.0 M	Stage II (引入)
可选角色注意力	1.2 M	Stage II (引入)
$\{q, k, v, o, \text{gate}, \text{up}, \text{down}\}_{\text{proj}}$ 上的 LoRA, rank 32	80.0 M	Stage II (引入)
辅助 VQ 头 (复用 lm_head)	0	复用, 无新参数
OA 掩码 + 重置钩子	0	非参数化
Stage II 可训练总量	$\sim 127\text{M}$	

OA 掩码本身是非参数化、按维度索引的选择；重置钩子是非参数化张量写入。逐阶段可训练参数： $\sim 7.0\text{B}$ (Stage 0) $\rightarrow \sim 23.8\text{M}$ (Stage I) $\rightarrow \sim 127\text{M}$ (Stage II)。

E 等变性质

命题。 假设：(i) 对象槽位不使用槽位索引位置嵌入；(ii) 单个帧组 G_t 内所有 $N+1$ 个槽位 token 共享公共 RoPE 位置索引 p_t (见附录 C)；(iii) 同一投影、注意力、前馈和世界头应用于每个对象槽位；(iv) 任意保持机器人 token 固定的对象槽位置换 π 都会一致地置换成对相对几何 G 和填充掩码 m 。则 OA-WAM 中的槽位感知 Chameleon 主干对对象槽位满足置换等变性：对输入对象槽位应用 π ，会对输出对象状态应用同一个 π 。

证明概要。 线性投影和前馈块在逐行共享，因此与 π 可交换。帧组内所有槽位 token 共享 RoPE 相位 p_t ，因此旋转 $R(p_t)$ 对所有槽位行是同一常矩阵；于是对任意槽位行置换 Π 有 $R(p_t)\Pi\mathbf{X} = \Pi R(p_t)\mathbf{X}$ ，即在假设 (ii) 下 RoPE 与槽位置换可交换。带掩码自注意力随后根据行特征（键使用 OA 掩码）计算成对分数，并加入 $\phi(G_{ij})$ 和双侧掩码 M_{ij} 。若一致置换 X 、 G 和 M ，注意力矩阵的行列也随之置换，因此 softmax 输出行以相同方式置换。对语言的交叉注意力对每个槽位使用相同语言键，因此也与槽位置换可交换。按层归纳可得，最终槽位状态和逐槽位世界预测是置换等变的。动作头对对象顺序置换不变，因为角色查询在带有相应置换掩码的 key-value 集上做注意力。

F 损失组件与增强

干扰物置换增强 ($\mathcal{L}_{\text{compose}}$, 第 1 部分)。 在 mini-batch 内，本文为每个样本识别既不是目标也不是参照物的槽位子集（可用时使用 Path T1 输出的弱标签，否则使用所有非机器人槽位）。随机采样这些位置的一个置换，并一致作用于 (i) 槽位嵌入，(ii) 成对几何张量 $\mathbf{G}$ ，(iii) 填充掩码。置换样本再前向通过模型；随后最小化 $\text{KL}(\alpha^{\text{orig}}.\text{detach} \parallel \alpha^{\text{aug}}) + \|\mathbf{A}_t^{\text{orig}}.\text{detach} - \mathbf{A}_t^{\text{aug}}\|_2^2$ ，确保模型的注意力和动作输出对干扰物重排保持不变。

干扰物插入增强 ($\mathcal{L}_{\text{compose}}$, 第 2 部分)。 从 batch 中另一样本随机采样一个干扰物槽位，并嫁接到当前样本的第一个填充槽位，重新计算 $\mathbf{G}$ 并将有效槽位数加一。应用同一 KL+L2 不变性损失。两种增强都进行 warmup: η_{compose} 在 Stage II 训练前 30% 从 0 线性升至 0.1，随后保持 0.1。

弱角色提示 ($\mathcal{L}_{\text{role}}$)。当演示包含目标/参照标签 (由 Path T1 加简单语言启发式抽取) 时, 鼓励动作头的两个逐步软槽位分配与这些标签对齐: $\mathcal{L}_{\text{role}} = \text{KL}(\alpha_0, \text{onehot}(\text{target})) + \text{KL}(\alpha_1, \text{onehot}(\text{ref}))$, 权重为 0.05, 只在 Stage II 训练前半段使用。50k 步之后设为零, 使模型在收敛时必须依赖自身学到的绑定, 而非辅助信号。

世界损失位姿归一化。平移在 MSE 前归一化到工作空间边界框 $[-1, 1]^3$; 旋转表示为 [100] 的 6 维连续参数化, 并在该 6 维空间中用 $\mathcal{L}_2$ 监督。消融中发现这严格优于四元数或轴角 MSE (未报告)。

辅助 VQ 损失日程。整个训练过程中, $\mathcal{L}_{\text{vq}}$ 权重固定为 0.04。由于主干和 lm_head 已在该目标上预训练, 不需要课程学习; 早期实验中继续增大权重会损害动作性能。

G 三阶段训练与推理延迟

Stage 0: 槽位感知主干预训练 (~600k steps)

设置。这是本文自己的基础模型预训练; 不使用任何先前机器人策略 checkpoint。完整 7B 主干从公开发布的 Chameleon-7B base 权重 [11] (多模态语言模型, 而非 VLA) 初始化, 然后在混合语料上端到端训练。OA 掩码阈值在前 5k 步从完整残差 (4096 维) 线性退火到 32 维硬形式, 这在结构上类似 Chameleon 自身的两阶段模态重加权课程 [11] 和 OmniTokenizer 的渐进联合训练 [78]; 之后保持硬形式, 因此 OA 约束在 99.2% 的预训练日程中有效施加。损失为 I-A 路径上的图像 VQ next-token 交叉熵, 加上式 (4) 的槽位级世界预测 MSE, 二者按后续同样的 0.04 vs. 1.0 权重求和, 不使用动作损失。

数据混合 (约 $\sim 2.5T$ token)。总 token 预算 = 全局 batch size 1024 $\times$ 序列长度 4096 $\times$ 600k 步。混合数据如下; 保留 Web 部分是防止 Chameleon-7B base 的多模态遗忘, 机器人部分提供槽位级世界预测信号。Web 图文使用 Chameleon 混合数据 [11] 的去重子集。

来源	Token	占比	覆盖的 token 路径
Web 图文	1.50 T	60%	T2 + I-A
Open X-Embodiment [58]	0.50 T	20%	全六路径
DROID [31]	0.20 T	8%	全六路径
RoboCasa [55]	0.20 T	8%	全六路径
Bridge V2 [75]	0.10 T	4%	全六路径
总计	2.50 T	100%	

对机器人来源, 槽位路径特征 (SAM 3 掩码 + DINOv3 嵌入 + 位姿) 在“冻结感知预计算”部分所述硬件上离线预计算。

优化器与日程。AdamW (β_1, β_2)=(0.9, 0.95), weight decay 0.05, 余弦日程衰减到峰值的 10%, 4k 步线性 warmup, 峰值 LR $1.5 \cdot 10^{-4}$, 梯度裁剪 1.0, bf16。硬件: 384 $\times$ A100-80GB (十二个节点, 每节点八张 A100, 节点内 TP=8、跨节点 DP=48), 墙钟时间约 ~ 18 天, 总计 $\sim 166k$ A100-hours。该配置吞吐约为 $\sim 4,200$ token/s/GPU, MFU 约 $\sim 60\%$, 与已发表的 7B 级 FSDP/Megatron 基准相当。输出为 ckpt-stage0.pt, 后续所有阶段均从该槽位感知 Chameleon-7B 主干开始。

Stage 0 可复现性说明。Stage 0 在等价于 384 $\times$ A100-80GB 的内部计算基础设施上完成。下游用户不需要复现 Stage 0: 发布的 ckpt-stage0.pt 与 Stage I/II 训练脚本足以得到所有报告数值, 只需在 8 $\times$ A100 上约 ~ 60 GPU-days。从零复现 Stage 0 需要约 $\sim 166k$ A100-hours, 相当于 Chameleon-7B 报告的 $\sim 856k$ A100-hour 预训练成本 [11] 的约 19%, 这对热启动适配而非从头预训练来说是合理预算。

Stage I: 槽位适配器对齐 (50k steps)

设置。冻结 Stage 0 的主干和 lm_head; 只训练槽位适配器 f_ϕ 、世界头 h_ψ 和地址流重置钩子 (总计 $\sim 23.8M$ 参数)。损失仅为 $\mathcal{L}_{\text{world}}$ 。数据为 LIBERO + DROID + Open X-Embodiment 的约 $\sim 100k$ episode 子集, 六路径全部离线缓存, 使每一步只涉及可训练模块和通过主干的一次冻结前向。虽然 OXE/DROID 数据与 Stage 0 有重叠, 但这里只有槽位适配器接收梯度, 主干权重冻结, 因此不存在通过主干测试集污染的风险。优化器: AdamW, $\beta_1 = 0.9, \beta_2 = 0.95$, weight decay 0.05, 梯度裁剪 1.0, 带 2000 步 warmup 的余弦日程, 峰值 LR $2 \cdot 10^{-4}$ 。Batch: bf16, 全局 batch size 256, 每 GPU batch size 8, 在 8 $\times$ A100-80GB 上梯度累积 4。墙钟时间: 3–4 天。

Stage II: 完整系统微调 (100k steps, LoRA 路线)

设置。在主干所有 $\{q, k, v, o, \text{gate}, \text{up}, \text{down}\}_{\text{proj}}$ 矩阵上挂载 rank $r=32$ 的 LoRA 模块 (LoRA $\alpha=64$, dropout 0.05, 总计 $\sim 80M$ LoRA 参数); 加入动作头 h_ϵ ($\sim 22M$, 外加可选 1.2M 角色注意力); Stage I

的槽位适配器和世界头继续更新。总可训练参数约 $\sim 127\text{M}$ 。损失为式 (6) 的完整 $\mathcal{L}(\theta)$ ， η_{compose} 在前 30k 步 ramp。数据仅为标准 LIBERO 演示，没有 LIBERO-Plus 扰动因子、增强基准标签，也没有超出上述弱角色提示的特权目标信息。优化器与 Stage I 相同；新模块和 LoRA 的 LR 为 $2 \cdot 10^{-4}$ ，任何解冻的基础主干参数 LR 为 $5 \cdot 10^{-6}$ (LoRA 路线中没有此类参数，但完整微调替代方案使用该 LR)。Batch: bf16，全局 batch size 128，每 GPU 4，在 $8 \times \text{A100-80GB}$ 上累积 8。EMA 衰减 0.999，梯度裁剪 1.0。墙钟时间：3–4 天。

完整微调替代方案。 为进行 sanity-check parity，本文还报告一个完整微调变体，即解冻整个 7B 主干（无 LoRA），以较低 LR $5 \cdot 10^{-6}$ 在相同硬件上训练 7–10 天。在 LIBERO 和 LIBERO-Plus 上，LoRA 与完整微调在每个报告轴上的差异均在 $\pm 1\%$ 内，因此主文默认使用 LoRA。

三阶段超参数表

超参数	Stage 0	Stage I	Stage II (LoRA)
可训练参数	$\sim 7.0\text{B}$	$\sim 23.8\text{M}$	$\sim 127\text{M}$ (80M LoRA + 47M heads)
优化器	AdamW	AdamW	AdamW
(β_1, β_2)	(0.9, 0.95)	(0.9, 0.95)	(0.9, 0.95)
weight decay	0.05	0.05	0.05
峰值 LR	$1.5 \cdot 10^{-4}$	$2 \cdot 10^{-4}$	新模块 / LoRA 为 $2 \cdot 10^{-4}$
LR 日程	余弦 $\rightarrow 10\% + 4\text{k warmup}$	余弦 + 2k warmup	余弦 + 2k warmup
总步数	$\sim 600,000$	50,000	100,000
batch size (全局)	1024	256	128
序列长度	4096	4096	~ 1200 (逐任务)
总 token	$\sim 2.5\text{T}$	—	—
精度	bf16	bf16	bf16
EMA 衰减	—	—	0.999
梯度裁剪	1.0	1.0	1.0
LoRA r, α , dropout	—	—	32, 64, 0.05
LoRA target	—	—	QKVO + gate, up, down_proj $\times 32$ layers
OA 掩码 warm-up	前 5k 步 (线性)	—	—
损失	VQ-CE + $\mathcal{L}_{\text{world}}$	$\mathcal{L}_{\text{world}}$	完整 $\mathcal{L}(\theta)$ ，式 (6)
η_{compose}	—	—	前 30k 从 0 $\rightarrow$ 0.1 ramp
$\mathcal{L}_{\text{role}}$ 权重	—	—	前 50k 为 0.05，之后为 0
硬件	$384 \times \text{A100-80GB}$	$8 \times \text{A100-80GB}$	$8 \times \text{A100-80GB}$
墙钟时间	~ 18 天 ($\sim 166\text{k A100-h}$)	3–4 天	3–4 天

评估运行时间

每次评估的墙钟时间。 在单张 A100 上，完整评估一次 LIBERO 需 1.7 小时 (4 个套件 $\times$ 100 个 episode $\times$ 3 个种子)，LIBERO-Plus 需 11.4 小时 (7 个轴 $\times$ 100 个 episode $\times$ 3 个种子)，SimplerEnv WidowX 四个 Bridge 任务的 visual-matching 评估需 1.6 小时。冻结感知预计算在 8 张 A100 上离线运行，为完整 LIBERO+LIBERO-Plus+SimplerEnv 缓存耗时 9.7 小时；缓存槽位使 SAM 3 和 DINOv3 的开销完全移出训练循环。

推理延迟分解

单张 A100 上的闭环控制。 每 16 个仿真步处理一次动作块，因此在 20 Hz 仿真器中的有效控制频率约为 $\sim 4.3\text{Hz}$ 。下表分解合计约 $\sim 233\text{ms/动作块}$ ：

阶段	墙钟时间 (单张 A100)
Stage 0 感知 (SAM 3 + DINOv3 + Qwen3-VL)	138 ms
SAM 3 (单帧、双视角、含概念跟踪)	73 ms
DINOv3 ViT-L/16 掩码池化	22 ms
Qwen3-VL-4B 名词短语解析 ($t=0$ 后缓存)	43 ms (仅首个动作块)
SEQUENCECONSTRUCTION (槽位适配器 + masked_scatter)	$\sim 5\text{ms}$
槽位感知 7B 主干前向 (Stage-0 ckpt)、FlashAttention-2、bf16、 $L \approx 1200$	80 ms
流匹配动作头，4 步 Euler	10 ms
每个动作块总计	$\sim 233\text{ms}$
有效闭环控制频率	$\sim 4.3\text{Hz}$

H 评估协议

LIBERO。 评估 Spatial、Object、Goal 和 Long 套件，每个套件 100 个 episode，三个种子。训练只使用标准演示。成功率为环境的任务完成信号。

LIBERO-Plus。 使用官方扰动生成器，并且不在扰动因子上训练。分别报告七个维度：object layout、background texture、light condition、camera view、robot initial state、language instruction 和 sensor noise。主文报告逐维成功率和七轴平均。

SimplerEnv。 在 WidowX (Bridge) 套件上使用官方 SimplerEnv visual-matching 协议 (Put Spoon on Towel、Stack Block、Put Carrot on Plate、Put Eggplant in Basket)。每个任务使用官方每格 25 个 episode，并重复三个种子。报告数值为每个任务的平均 visual-matching 成功率；表 1 的 avg. 列对四个 Bridge 任务取平均。

统计。 对每个成功率计算种子均值。扰动强度曲线在方法间使用相同种子。

结果来源。 *LIBERO* 行：OpenVLA 来自 [32]；SpatialVLA 来自 [62]； π_0 来自 [3]； $\pi_{0.5}$ 来自 [60]；InternVLA-M1 来自 [14]；F1-VLA 来自 [52]；MemoryVLA 来自 [66]；VLA-JEPA 来自 [73]；CoWVLA 来自 [85]；ThinkAct 来自 [27]；VITA 来自 [53]。CogACT [39] 的主论文未报告 *LIBERO*，因此该行留空。*LIBERO-Plus* 行：OpenVLA-OFT、 π_0 逐轴数值来自 *LIBERO-Plus* 报告 [19] 的表 2； $\pi_{0.5}$ 数值来自本文运行发布 checkpoint；ABot-M0 来自 [87]；X-VLA 来自 [97]；WorldVLA 来自 [10]；VLA-JEPA 来自 [73]；GE-Act 来自 [42]；Cosmos-Policy 来自 [34]。本文严格使用官方 *LIBERO-Plus* 扰动生成器，并且不在扰动因子上重训。*SimplerEnv* (*WidowX*) 行：SpatialVLA 来自 [62]；InternVLA-M1 来自 [14] (表 2，明确标注 visual matching)；CogACT 来自 [39] (表 2 图注明确说明 visual-matching 设置)；MemoryVLA 来自 [66]；VLA-JEPA 来自 [73] 中明确标注的 visual-matching 协议；CoWVLA 来自 [85]；F1-VLA 的逐任务数值来自 [52] 的表 3 (avg 单元格留空，因为 F1 论文使用不同聚合方式)；ThinkAct 来自 [27] (表 1，小节明确标注 “Simpler-Bridge (Visual Matching)”)；VITA 来自 [53] (VITA 论文未明确说明协议，但 SIMPLER 对 WidowX (Bridge) 套件只提供 visual-matching 模式，因此将其数值列入 visual-matching 列)；OA-WAM 来自本文在官方 visual-matching 协议下运行发布 checkpoint，每格 25 个 episode，三个随机种子。OpenVLA、 π_0 和 $\pi_{0.5}$ 的 *SimplerEnv* 单元格留空：其主论文未发布 visual-matching 协议下的 *SimplerEnv* WidowX (Bridge) 数值，本文为使每个单元格都能归因到一个命名的一手来源，刻意排除第三方复现。

I 消融、公平性控制与失败审计

补充消融：A3（世界头）和 A4（干扰物一致性）

A1 和 A2（两个摘要级架构声明）已在主文中报告 (§4.3)；A3 和 A4 进一步支撑联合世界预测目标和干扰物一致性正则项两个辅助声明，并与 A1 因子实验的 V3 角点一起在此报告，用于进一步分解 OA 约束中的键掩码与地址重置组件。

表 5: A3: 世界预测头。禁用未来预测会移除多步槽位世界损失 $\mathcal{L}_{\text{world}}$ ，只保留动作和辅助 VQ 损失。世界头尤其提升 LP camera (禁用后 -7.1%) 和 *LIBERO* (禁用后 -2.2%)；LP avg 在统计上基本持平 (action-only 为 +0.6%，处于种子噪声内)，说明世界头贡献具有几何轴特异性，而非通用容量增益。

	世界头	LIBERO	LP camera	LP avg
仅动作		95.6	73.4	84.5
含世界头 (本文)		97.8	80.5	83.9

表 6: A4: 干扰物一致性损失。移除 $\mathcal{L}_{\text{compose}}$ (置换和插入组件均移除) 会使 LP layout 下降 4.3%，并使置换 KL 和插入漂移约升高 5 $\times$ ；该损失确实承担关键作用，而非装饰性组件。

	一致性损失	LP layout	perm. KL $\downarrow$	ins. drift $\uparrow$
无		78.5	0.21	0.19
完整 (本文)		82.8	0.04	0.05

A1 的 V3: 每层地址重置钩子因子分解

表 7 添加 A1 背后 2 $\times$ 2 因子设计的第四个角点：V3 保留仅地址键投影，但移除每层地址重置钩子，使地址子向量在第 0 层之后可通过残差流漂移。V3 在所有指标上位于 V0 (完整) 和 V1 (关闭掩码、开启钩子) 之间，表明：(i) 每层钩子是必要的；没有它， $\ell \geq 1$ 层的键不再是纯地址，因此式 (3) 的 OA 约束只在第一层严格成立；(ii) 只关闭掩码 (V1) 对鲁棒性的影响更大。两部分各自都有承重作用，并在一起使用时复合：在 LP avg 上 $(V0 - V3) + (V0 - V1) \approx 0.7 + 3.1 = 3.8\%$ ，而 $(V0 - V2) = 7.7\%$ ，留下约 $\sim 3.9\%$ 的超加性交互项，即同时移除二者的伤害超过单独移除之和。

鲁棒性收益的架构归因。 图 6 将同一个 2 $\times$ 2 因子实验可视化作为一种分解，用以区分 OOD 鲁棒性有多少来自槽位 token 加冻结感知栈本身，又有多少来自其上的 OA 约束。**V2** 是自然的“仅槽位”对照：它保留完整 SAM 3 + DINOv3 + Qwen3-VL 感知、槽位适配器、世界/动作头和主干权重，但禁

表 7: A1 的 V3: 每层地址重置钩子因子分解。与表 3 中的 V0/V1/V2 比较; 四行共同构成 (键掩码, 重置钩子) 上的 2×2 因子实验。

变体 (A1)	K 掩码	重置钩子	LIBERO	LP camera	LP avg	交换绑定
V2 (无 OA)	off	off	95.4	60.5	76.2	0.06
V1 (关闭掩码, 开启钩子)	off	on	96.3	67.2	80.8	0.19
V3 (开启掩码, 关闭钩子)	on	off	96.6	70.8	83.2	0.32
V0 (完整 OA-WAM)	on	on	97.8	80.5	83.9	0.87

用仅地址键掩码与每层重置钩子, 即槽位 token 仍流入主干, 但 OA 约束被移除。从 V2 到 V0 (完整 OA-WAM) 使 LP-camera 增加 +20.0% (60.5 $\rightarrow$ 80.5), LP-avg 增加 +7.7% (76.2 $\rightarrow$ 83.9), 而标准 LIBERO 只增加 +2.4%, 显示收益来自 OOD 特定路由而非重型感知栈带来的通用容量。面板 (b) 在因果交换绑定指标上展示相同分解: V2 为 0.06, 甚至低于最强整体式基线 (0.09), 而到 0.87 的提升随着重新引入掩码和钩子单调发生。




图 6: OA-WAM 鲁棒性收益的架构归因。表 7 背后 2×2 因子实验的分解。(a) 四个变体在 LIBERO / LP-camera / LP-avg 上的成功率。V2 是仅槽位对照 (完整感知栈, OA 约束关闭); V0 是完整 OA-WAM。OA 约束在最几何的轴 (LP-camera) 上增加 +20.0%, 而标准 LIBERO 几乎不变, 将收益隔离为 OOD 特定路由, 而非额外容量。(b) 相同变体在交换绑定余弦上的结果 (表 4); 虚线表示八个整体式 VLA/WAM 基线中达到的最大余弦。

诊断指标

表 8: LIBERO-Plus 上的诊断指标。Target attn. 是角色查询 r_1 分配给真值目标槽位的平均注意力质量。Swap binding 是末端执行器残差轨迹与交换方向的余弦对齐。Failure 列报告由于暴露的感知或策略错误导致评估 episode 失败的比例; 整体式基线没有暴露的感知缓存, 因此其全部失败都归因到策略侧。

方法	target attn. $\uparrow$	swap binding $\uparrow$	perm. KL $\downarrow$	action L2 (m) $\downarrow$	ins. drift $\downarrow$	perc. / pol. failure (%)
OpenVLA	n/a	0.04	0.96	0.241	0.83	0 / 82.7
π_0	n/a	0.05	0.62	0.183	0.71	0 / 46.4
OpenVLA-OFT	n/a	0.06	0.51	0.156	0.65	0 / 30.4
$\pi_{0.5}$	n/a	0.05	0.29	0.107	0.42	0 / 14.3
WorldVLA	n/a	0.09	0.38	0.131	0.52	0 / 75.0
VLA-JEPA	n/a	0.07	0.34	0.122	0.48	0 / 20.5
Cosmos-Policy	n/a	0.06	0.31	0.118	0.46	0 / 17.8
GE-Act	n/a	0.07	0.36	0.125	0.50	0 / 19.7
OA-WAM (本文)	0.81	0.87	0.04	0.018	0.05	3.4 / 7.2

本文有意省略的比较

本文考虑并删去了若干额外比较, 因为它们要么只测量工程旋钮且没有对应的摘要级声明, 要么已被 A1 涵盖, 要么是鲁棒性边界而非受控消融; 若将每个都作为单独表格记录, 会稀释而不是强化上述四个可证伪陈述。(a) 几何偏置选择 (相对 SE(3) 偏置 vs. 绝对位姿 vs. 无) 已作为设计决策报告在 §3.3; 早期实验中移除该偏置使 LP camera 下降约 $\sim 2\%$, 但不改变任何 A1 结论的符号。(b) 动作头变体 (均值池化、硬角色分类器、无查询自注意力) 部分由表 4 的 mean-pool 行覆盖, 因为 A1 已表明在保持头部不变时翻转 OA 约束会以关键量级改变绑定和 OOD 成功率; 因此不再逐一列出所有头部变

体。(c) 角色辅助权重 $\lambda_r = 0.05$ 从 $\{0, 0.05, 0.5\}$ 中在 held-out 验证切片上选择，并视为超参数（分布内差异 $\leq 1.4\%$ ）。(d) 测试时位姿噪声和可见槽位数是鲁棒性边界而非消融，并已在结论的局限性段落中总结；在评估时注入 $5\text{ cm}/20^\circ$ 位姿噪声后，OA-WAM 仍保持 LP avg 78.2（高于 OpenVLA-OFT 和 X-VLA，低于 $\pi_{0.5}$ ）；测试时只有 2 个可见槽位时保持 LP avg 79.7。(e) 角色查询数 $R=4$ 对应 target/reference/tool/distractor 四个软角色，同样视为超参数； $R=2$ 分配不足（LP avg -6.8% ）， $R=8$ 增加容量但没有可测收益。上述 (a)–(e) 都不直接针对摘要中的两个架构声明；把它们列为消融会把审稿注意力从真正关键的四项上移开。

失败模式分解

本文对 LIBERO-Plus 上随机采样的 300 个 OA-WAM 失败 episode 进行事后人工标注，并按最主要责任组件分组。分解主要由四类构成。(i) 动作/动力学（121 个 episode，40.3%，可通过更好策略解决）：策略到达正确目标物体，但接触角度或位置错误，这是动作头和动力学损失的问题，而非槽位接口问题。(ii) 槽位提取/感知（共 89 个，29.7%，可通过更好感知或位姿解决）可再分为 SAM 3 概念分割/跟踪导致的目标掩码漂移（51，17.0%），以及对称或透明物体上深度位姿来源而非主干造成的位姿错误（38，12.7%）。(iii) 工程（47，15.7%，可通过延迟优化解决）：冻结感知栈落后于实时控制。(iv) 范围外假设（共 43，14.3%，位于策略/感知栈之外）可再分为干扰物物理阻塞目标从而违反弱耦合假设（24，8.0%），以及多个候选都匹配的真正歧义指令（19，6.3%）。OA-WAM 本身可直接改进的两类，即感知（89，29.7%）和动作（121，40.3%），合计覆盖约 70% 的失败。

基准任务图集




图 7: 四个 LIBERO 套件 [45] 的代表任务: **Spatial** (10 个任务, 目标相同但初始空间布局不同), **Object** (10 个任务, 同一场景但目标物体不同), **Goal** (10 个任务, 同一场景但目标谓词不同), 以及 **Long** (10 个长时程组合任务)。




图 8: 四个 SimplerEnv WidowX (Bridge) 套件 [40] 的代表任务: **Spoon-Towel** (必须从桌面拿起勺子并放到毛巾上), **Carrot-Plate** (必须把胡萝卜放到黄色盘子上), **Stack-Cube** (必须把绿色方块叠到黄色方块上), 以及 **Eggplant-Basket** (必须把茄子放入黄色篮子中)。




图 9: **LIBERO-Plus** 扰动图集。可视化 LIBERO-Plus 的七个扰动轴（列：Objects Layout、Background Textures、Light Conditions、Camera Viewpoints、Robot Initial States、Language Instructions、Sensor Noise），并作用于四个 LIBERO 套件（行：Spatial、Object、Goal、Long-horizon）。每一行固定同一基础场景，使该行七个面板共享相同物体和目标，从而隔离每个轴的视觉效果。Layout 列加入干扰物，Background 替换桌面/地面纹理，Light 改变光照强度和颜色，Camera 改变智能体视角外参，Robot init 扰动机械臂初始关节构型。语言指令扰动只改变文本，因而视觉上与锚定场景一致；该扰动只通过输入策略的 prompt 体现。Noise 列有意在各行使用不同退化，即 motion blur、Gaussian blur、zoom blur 和 glass blur，以展示 LIBERO-Plus 中传感器噪声变体的多样性。